



中国海洋大学  
OCEAN UNIVERSITY OF CHINA

# 硕士学位论文

MASTER DISSERTATION

论文题目: \_\_\_\_\_

英文题目: \_\_\_\_\_

作 者: \_\_\_\_\_

指导教师: \_\_\_\_\_

学位类别: \_\_\_\_\_

专业名称: \_\_\_\_\_

研究方向: \_\_\_\_\_



年 月 日



谨以此论文献给所有关心支持我的人

-----XXX



# 基于智能手表惯性传感器的手写识别和窃听技术研究

(论文研究由国家自然科学基金项目#61379128 资助)

学位论文答辩日期: \_\_\_\_\_

指导教师签字: \_\_\_\_\_

答辩委员会成员签字: \_\_\_\_\_

\_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_



## 独 创 声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含未获得（注：如没有其他需要特别声明的，本栏可空）或其他教育机构的学位或证书使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：                    签字日期：      年    月    日

---

## 位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，并同意以下事项：

1、学校有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。

2、学校可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同时授权清华大学“中国学术期刊(光盘版)电子杂志社”用于出版和编入 CNKI《中国知识资源总库》，授权中国科学技术信息研究所将本学位论文收录到《中国学位论文全文数据库》。（保密的学位论文在解密后适用本授权书）

学位论文作者签名：

导师签字：

签字日期：      年    月    日

签字日期：      年    月    日





---

# 基于智能手表惯性传感器的手写识别和窃听技术研究

## 摘 要

近年来，智能手表开始广泛进入人们的生活，其内置的多种 MEMS 惯性传感器（加速度计、陀螺仪、磁力计等）能感知用户的动作，提供诸如步数、睡眠质量等健康相关数据。然而，智能手表所记录的用户动作数据可能蕴含着还原用户动作的可能，并可能造成用户部分敏感信息的泄露。

目前，已有基于惯性传感器的手写识别技术多需要用户书写较大幅度，并且保持手腕和笔尖运动轨迹一致；同时，字母切割需要借助打点、停顿等特殊标记，均不符合人们日常的写字习惯。已有的基于惯性传感器的窃听技术则侧重利用手腕运动轨迹还原被攻击者的键盘击键，或者通过窃听在木质桌面的书写声音猜测手写内容。上述研究的限定条件使得用户在纸面上的自然手写动作仍然不能被识别。

因此，本文面向用户在纸面上书写的日常动作，提出基于智能手表惯性传感器的手写识别系统和手写窃听系统，通过分析手腕运动数据还原用户书写的内容，并评估惯性传感器数据在不同条件下的泄密风险。

在完成书写数据收集实验的基础上，本文发现基于智能手表惯性传感器识别或窃听用户书写的主要难点为：不同用户的书写习惯不同；同一用户无法保证在每次书写时有相同的执笔姿势等初始状态；书写时手腕的动作幅度远小于笔尖的运动幅度。针对上述挑战，本文使用加速度计和陀螺仪数据完成连续书写过程中的单词与字母切割，提取 115 个与字母结构相关的有效特征集合，使用随机森林分类器识别单个字母，进而经过字典校正拼写获得预测单词。手写识别系统使用了同一用户的书写数据进行训练，解决用户相关的手写识别问题。然后，本文探索基于用户独立的手写窃听问题，使用来自其他用户的手写数据进行训练，并对当前用户的手写行为进行猜测。

本文对手写识别和手写监听系统的性能进行了实验评估。实验结果表明：用户在使用标准手写格式书写小写的英文单词时，智能手表惯性传感器捕捉到的手腕运动信号可以用于还原手写内容，字母和单词识别率分别为 86.24% 和 69.36%。对于利用其他用户数据训练并窃听当前用户书写内容的场景，top-1 单词预测结果的平均准确率为 32.75%，top-5 的平均单词准确率为 48.80%，揭示了智能手表惯性传感器收集的手腕运动信息存在泄露部分书写内容的风险。

**关键词：惯性传感器；手写识别；手写窃听；智能手表**

---

---

# **Research on Handwriting Recognition and Eavesdropping Technology Based on Inertial Sensors of Smartwatch**

## **Abstract**

In recent years, smartwatch has immersed in people's lives. There are various built-in MEMS inertial sensors (accelerometers, gyroscopes, magnetometers, etc.) that can record user's actions and provide health-related data, such as step counts and the sleep quality. However, the activity data recorded by the smartwatch may contain the possibility of reconstructing the user's actions, and may cause leakage of some sensitive information of the user.

At present, there are many handwriting recognition technologies based on inertial sensors that require the user to write in a large size and keep the trajectory of the wrist and the pen consistent. Besides, letter segmentation requires special marks such as dots and pauses, which do not meet people's daily writing habits. Existing eavesdropping technology based on inertial sensors focuses on using the wrist motion trajectory to reconstruct the attacker's keystrokes, or guessing the handwriting content by eavesdropping on the writing sound that produced on the wooden desktop. The limitations of the above studies result in a low letter recognition accuracy when a user writes on the paper naturally.

Therefore, this paper aims at the daily movements of users when writing on papers, and proposes a handwriting recognition and handwriting eavesdropping system based on the inertial sensors of smartwatch. These two experiments are able to reconstruct handwriting of users and evaluate the risk of information leakage respectively.

On the basis of completing the data collection experiment, this paper finds that the main difficulties in recognizing or eavesdropping the user's writing based on the inertial sensor of the smartwatch are: the writing habits of different users are different; the same user cannot guarantee the same writing states like initial writing posture and etc.; the wrist movement when writing is much smaller than the movement of the pen tip. In response to the above three challenges, this paper uses accelerometer and gyroscope data to solve the word and letter segmentation problems in the continuous writing process, and extracts 115 effective features related to the letter structure, as well as uses Random Forest classifier to identify a single letter, and then develop spellcheck through dictionary for word prediction. The handwriting recognition

---

system uses the same user's written data to train and solve user-related handwriting recognition problems. Then, this article explores a user-independent writing eavesdropping problem, which uses handwritten data from other users to train, and guesses the current user's handwriting behavior.

This paper evaluates the performance of handwriting recognition and handwriting eavesdropping system. The experimental results show that when the user writes lowercase English words in the standard handwritten format, the wrist movement signal captured by the smartwatch's inertial sensor can be used to reconstruct the handwritten content, and the letter and word recognition rates are 86.24% and 69.36% respectively. For the scenario that trains by other user's data and eavesdrops the handwriting himself, the average accuracy rate of the top-1 word prediction result is 32.75%, and the average word accuracy rate of top-5 is 48.80%, revealing the handwriting data collected by the inertial sensors of smartwatch has the possibility to leak some of the written content.

**Keywords: motion sensors; handwriting recognition; handwriting eavesdropping; smartwatch**

---

# 目录

<b>1 引言</b>	<b>1</b>
1.1 研究背景和意义	1
1.2 研究现状	2
1.2.1 基于手写英文字母识别的研究	2
1.2.2 基于手写英文字母监听的研究	3
1.2.3 研究面临的问题与挑战	3
1.3 研究内容与贡献	4
1.4 论文组织结构	5
<b>2 相关技术及工作</b>	<b>7</b>
2.1 基于惯性传感器的手写识别方法概述	7
2.2 基于智能设备的手写窃听方法概述	9
2.3 相关技术简介	10
2.3.1 Android Wear	10
2.3.2 隐马尔科夫模型 (HMM)	11
2.3.3 支持向量机 (SVM)	12
2.3.4 随机森林 (Random Forest)	13
2.4 本章小结	14
<b>3 数据收集与分析</b>	<b>15</b>
3.1 Android Wear 应用程序开发	15
3.2 实验设计与手写动作数据收集	16
3.2.1 采集手写动作实验设计与数据收集	16
3.3 观察惯性传感器数据	18
3.3.1 异常值分析	18
3.3.2 噪音分析	19
3.3.3 笔尖与手腕运动差异	21
3.3.4 同一用户字母样本差异	22
3.3.5 小写英文字母笔画设计冗余	22

---

3.4 本章小结 .....	23
<b>4 手写识别系统 .....</b>	<b>24</b>
4.1 系统概述 .....	24
4.2 数据预处理 .....	25
4.2.1 异常值处理.....	25
4.2.2 低通滤波器.....	26
4.3 字母及单词切割 .....	26
4.3.1 字母切割.....	27
4.3.2 单词切割.....	29
4.4 特征提取 .....	30
4.4.1 特征枚举.....	30
4.4.2 特征选择.....	35
4.5 字母识别及评估 .....	36
4.5.1 实验设计.....	37
4.5.1 实验评估.....	37
4.6 单词识别及评估 .....	39
4.6.1 单词识别实验.....	39
4.6.2 单词识别系统评估.....	40
4.7 本章小结 .....	41
<b>5 手写窃听系统 .....</b>	<b>42</b>
5.1 系统概述 .....	42
5.2 字母识别及评估 .....	43
5.2.1 字母识别实验设计.....	43
5.2.2 字母识别系统评估.....	43
5.3 单词识别及评估 .....	44
5.3.1 单词识别.....	44
5.3.2 单词识别系统评估.....	45
5.4 本章小结 .....	46
<b>6 总结与展望 .....</b>	<b>47</b>

---

6.1 总结 .....	47
6.2 展望 .....	47
参考文献 .....	49
致谢.....	53
个人简历、攻读硕士学位期间发表的学术论文.....	54

# 1 引言

二十一世纪，人类切身感受到了科技进步给生活带来的便利，尤其是近年来可穿戴式电子产品的问世和普及，给发展智能工厂<sup>[1]</sup>和手势识别<sup>[2]</sup>提供了新思路，但设备记录的用户信息也为窃听提供了新的渠道，为科研工作同时带来了机遇和挑战。

一方面，许多可穿戴设备内嵌有多种惯性传感器和麦克风，这些传感器能够实时捕获用户手腕的细微活动以及周围环境信息。通过不同算法，科研人员能够还原用户特定时间内的运动情况，甚至在不需要额外辅助设备的前提下完成手写识别，这是机遇。另一方面，尚未有人详细评估可穿戴设备在不同场景下收集的动作和声音等信号能否泄露用户隐私、泄露多少隐私，是可穿戴设备普及带来的挑战。

本章首先概述对基于智能手表惯性传感器的手写识别和手写窃听技术的研究背景和意义。然后，分析已有的科研工作研究成果，总结本文研究主要面临的 5 项难点和挑战。接着，概述本文的研究内容并总结文章的 2 项主要贡献。最后，展示全文的组织结构。

## 1.1 研究背景和意义

近年来，智能手表开始进入人们的生活，其内置的多种 MEMS 惯性传感器（加速度计、陀螺仪、磁力计等）能感知用户的动作，提供诸如步数、睡眠质量等健康相关数据。然而，智能手表惯性传感器所记录的用户动作数据可能蕴含着还原用户书写内容的可能，并可能造成部分书写信息的泄露。

目前主要的文字输入方法分为三类：键盘输入<sup>[3,4]</sup>，图像识别<sup>[5]</sup>和手写识别<sup>[6,7,8]</sup>。相较前两种文字输入方式，手写识别具有两大优点：（1）用户在书写的过程中能对加深对文字的记忆<sup>[9]</sup>；（2）在写作时激发作者的创作力<sup>[10]</sup>。然而，现有的手写识别技术通常需要借助写字板、触摸屏等设备，仍然和用户在纸面上的自然手写有所区别。

智能手表的兴起给手写识别的普及带来了全新的思路。如 LG Watch R、Samsung Gear、Apple Watch 等电子设备不仅具有编程能力，同时内嵌了多种传感器硬件，包括加速度计、陀螺仪、磁力计，为研究人员提供了分析用户动作的可能<sup>[11,12]</sup>。同时，Apple Watch、Android Wear、Fitbit 等可穿戴设备通常只有一个小屏幕交互区域，而正常人的手指大小占据屏幕的较大区域面积，无法实现精准地输入，造成“Fat finger”<sup>[13]</sup>问题。



此外，智能设备和传感器的普及也造成了新的信息泄露风险。研究者已经指出：通过收集声音信号<sup>[14]</sup>、运动信号<sup>[15]</sup>等途径，有可能窃听到用户的键盘击键值或者用户在木质桌面上的部分书写内容。

综上所述，基于可穿戴设备惯性传感器的动作识别技术已经得到越来越多的关注，其应用场景逐渐覆盖各个行业领域，促进着人机交互技术的发展。但是，面向用户在纸面上自然书写，使用智能手表惯性传感进行手写识别的研究仍有待于探索。一方面，该研究能够使用户在输入时，不再局限于智能手表的触摸屏，解决了“Fat Finger”问题；另一方面，也可能揭示智能手表上的应用窃听用户手写内容的风险。

## 1.2 研究现状

本节将分别介绍基于智能手表惯性传感器的手写识别和手写窃听两个课题的研究现状，分析目前这两种技术面临的主要问题和挑战。

### 1.2.1 基于手写英文字母识别的研究

随着穿戴式电子设备的发展，研究者们开始探索进行基于惯性传感器的手写识别研究，主要研究成果可分为 2 类：

(1) 三维空间手写识别研究。文献<sup>[16]</sup>设计了一副具有加速度传感器的手套，用户在空中书写大写字母，同时通过打点的方式辅助切割。手套能记录用户手指在空中的运动轨迹，并通过 HMM 分析出写字内容。

(2) 二维平面手写识别研究。面向白板书写场合：文献<sup>[17,18]</sup>提出，当用户在竖直白板上书写较大幅度的大写字母时，智能手表的惯性传感器能够间接跟踪笔尖运动，还原用户所书写的内容。面向纸面书写场合：Arduser 等<sup>[19]</sup>研究面向纸面书写的大写英文字母手写识别，该研究要求用户保持手腕和笔尖活动的一致，保证智能手表的惯性传感器能直接记录笔尖的运动轨迹，然后通过加速度和陀螺仪还原出写字内容。GyroPen<sup>[20]</sup>提出将手机作为笔在桌面上书写，用户在保持手机与桌面夹角基本不变的情况下，通过手机记录下来的角速度数据分析手机在纸面上的运动轨迹，然后作者通过图像识别的方法分析该轨迹由哪些字母组成。Li 等<sup>[21]</sup>提出在纸面上书写小写字母的手写识别方法，该方法要求以单个字母为单位，需要用户在书写完一个字母后立即在智能手表上确定识别准确与否，降低了文字输入效率。

上述研究成果的主要限制为：要求用户的书写字体较大；要求用户在书写过程中保持手腕和笔尖运动一致或执笔与桌面的夹角不变；要求用户写完一个字母后在智能手表上确认。这些限制与用户在纸面上自然书写的场景有一定差距。在

纸面上的自然书写时,用户的正常字体小于上述研究的要求,而且用户的手腕动作幅度远低于笔尖的运动幅度,同时用户通常连续书写字母或单词。

### 1.2.2 基于手写英文字母监听的研究

在手写识别研究取得进展时,研究者也开展了可穿戴设备记录的传感器数据是否能够造成信息泄露的研究。文献<sup>[22,23,24,25]</sup>的研究结果表明:敲击键盘或使用电子触摸屏时的手腕加速度数据、写字时的声音,都包含一定的手写信息。通过动作识别和字典校正,窃听有可能获得 50% 左右的手写内容,引发信息泄露风险。

首先,因为键盘或触摸屏上的按键位置相对固定,通过大量收集用户击键行为,处理惯性传感器数据,有可能猜测当前击键内容并预测同一用户在后续时间的击键。**Liu**<sup>[26]</sup>和 **Maiti**<sup>[27]</sup>等分析了志愿者在使用键盘和触摸屏时的手表加速度传感器数据,还原出受害者 50% 以上的相应击键信息。

声音信号也能造成信息泄露。**WritingHacker**<sup>[28]</sup>使用手机麦克风窃听用户在木制桌面上的手写动作的声音,进行手写内容的猜测。该研究将 26 个大写英文字母按照笔画数分割成三类,然后寻找在书写不同笔画时的不同声音特征区分字母,在实验木制桌面的识别准确率 50% 左右。

因此,关于智能手机惯性传感器记录的运动数据能否泄露用户在纸面上自然书写信息,也是有待研究的信息安全问题。

### 1.2.3 研究面临的问题与挑战

本文的手写识别和手写窃听研究,目标是尽量贴近人们的日常写字幅度与习惯。但是,日常人们的写字习惯各不相同,写字速度快、幅度小也给研究工作带来了不小的困难。在研究小写英文字母并且限制标准手写模式的场景下,本文发现存在以下五项主要挑战:

(1) 小幅度动作的切割问题。在小幅度动作数据中,环境噪音对手写数据影响明显。因此,寻找静止时间段和写字动作的具体边界也比大幅度动作手写识别困难。

(2) 笔尖与手腕运动不一致。手腕通过顺时针和逆时针旋转带动笔尖运动,但是手腕运动轨迹和字母笔画结构并不是一一对应的。本文需要找到手腕活动与字母笔画的映射关系,通过分析手腕运动轨迹识别不同字母。

(3) 寻找只与字母结构有关的分类特征。人不可能完全重复两次相同写字动作,相同字母的传感器数据必然随着该用户握笔姿势、写字速度等因素的变化而改变。因此,简单地提取时域和频域特征并不能保证小幅度动作识别的准确率和鲁棒性。本文需要寻找能够反映字母本身固有结构的特征提高分类效果。

(4) 26 个英文小写字母字形相近, 导致区分难度较大。字母的笔画设计存在冗余, 也存在某些字母的笔画完全包含在另一个字母内的情况, 这致使某些字母结构类似, 较难区分<sup>[29]</sup>。

(5) 窃听问题中无本人手写字母训练样本。窃听活动无法获取受害者本身的训练数据, 如何通过他人的数据识别受害者本人的手写内容是手写窃听实验的最大问题。

### 1.3 研究内容与贡献

针对上述五项挑战, 本文开展了手写数据收集实验; 接着从收集的数据中设计了单词和字母切割算法; 然后针对字母识别问题开展了特征筛选研究, 使用随机森林完成了字母识别; 进而以单词为单位使用字典进行校正, 完成了自然书写的识别研究。随后, 本文探讨了在没有被攻击者书写数据的限制下, 构建了基于智能手表惯性传感器的监听实验, 揭示了可能存在的智能手表应用窃听用户手写内容的风险。具体的研究内容如下:

(1) 手写数据收集。本文针对 LG R 型号智能手表, 在 Android Wear 平台下开发了手写数据收集程序。在此基础上, 本文共招募了 10 名志愿者参与实验, 随机分成每组五人的 A 组和 B 组, 在一周内共收集了 19500 个标准小写英文字母数据和 2010 个英文单词样本。针对手写识别和监听两种场景, 本文对两组人员开展了独立的数据收集实验。

A 组五名志愿者在连续 6 天内, 每天需按照标准英文手写体格式抄写英文字母, 同时, 每人抄写两段来自不同领域的文章各一次。另一方面, 对于来自 B 组的志愿者, 每人抄写上述两段文字各一次, 为了更加真实地贴近现实的窃听场景, 相较 A 组成员, B 组志愿者在书写文字时并未被告知本次实验的目的, 也没有抄写小写英文字母。

(2) 单词和字母切割。针对用户在纸面上连续书写的应用场景, 本文首先需要从惯性传感器记录的动作数据序列中实现单词和字母的切割。对于一段连续时间内的采样序列, 除了正常的写字行为外, 还存在大量其他动作, 包括: 移动手腕位置、静止不动等。在比较不同类型动作的特征后, 本文发现不同动作在陀螺仪振幅、相位差、加速度能量大小等特征上的差别, 并以此为依据确定单词和字母的边界。

(3) 字母和单词识别。针对如何区分不同字母样本的问题, 本文发现在书写 26 个小写英文字母时, 因为字形结构的差异, 手腕改变转动方向和速度具有一定的可区分性。因此, 本文从手腕运动信号中提取特征, 用以反映字母固有的结构信息。并且, 提取的特征要满足: 受写字初始位置、写字习惯、书写速度等

因素影响较小。然后，使用随机森林分类器针对用户自己的书写训练样本完成训练，并对分类同一用户的测试样本的字母，完成字母识别。在字母识别的基础上，本文进一步使用字典针对一个单词的字母识别结果进行校正，提高单词的识别率。

(4) 窃听系统。为进一步揭示智能手表上的应用可能使用惯性传感器信息来窃听用户手写内容的危险，本文设计并实现了基于智能手表惯性传感器的手写窃听系统。该系统与手写识别系统的最主要的不同为：使用其他用户的手写数据样本训练分类器，并猜测当前用户的手写内容。实验结果确认了智能手表惯性传感器能够窃听部分用户手写内容的风险。

本文的主要贡献如下：

(1) 本文根据不同小写英文字母的结构，设计了反映字母结构相关的相位相关特征集，在此基础上实现了基于智能手表惯性传感器的手写识别系统。实验表明，相位相关特征对区分不同结构的字母效果良好。

(2) 评估手腕运动是否泄漏手写信息。本文设计实现的基于智能手表惯性传感器的手写窃听系统，通过实验解释了智能手表应用存在能够窃听用户手写部分内容的风险。

## 1.4 论文组织结构

全文共分为六个章节，具体安排如下：

第一章 引言。主要阐述了基于惯性传感器的手写小写英文字母识别和窃听研究的背景和意义，归纳了手写小写英文字母识别和窃听技术在国内外的研究现状，并且详细分析了本研究课题当前面临的挑战，最后总结了本文的主要研究内容和贡献。

第二章 相关技术及工作。本章总结概括了基于惯性传感器手写小写英文字母识别和窃听的理论基础，概述现有技术和研究的思路和架构，并指出了现有技术在方法上的不足。

第三章 数据收集与分析。本章首先介绍手写小写英文字母识别和窃听两项实验的数据收集过程，通过对已有数据观察分析后，提出去除异常值和噪音的必要性，以及单词切割与分类的可行方案。

第四章 手写识别系统。本章首先对用户依赖的手写识别系统进行概述，然后介绍该系统的预处理、切割方法、特征提取、字母和单词识别等主要模块。最后对该系统的性能进行实验评估。

第五章 手写窃听系统。本章首先对用户独立的手写窃听系统进行概述，然后结合手写识别系统，介绍窃听系统的切割方法、字母识别、单词识别等主要模块。最后对该系统的性能进行实验评估。

第六章 总结与展望。本章将总结全文，并展望今后研究方向。

## 2 相关技术及工作

本章将对文中涉及的相关技术与代表性工作进行详细介绍，然后总结当前方法存在的不足，最后，对本章进行总结。

### 2.1 基于惯性传感器的手写识别方法概述

本节将重点讨论基于惯性传感器的手写识别方法和发展，相关技术主要分为以下 2 类：

(1) 三维空间手写识别方法。该思路首先是由 Amm 在论文<sup>[30]</sup>中提出。每位志愿者需佩戴一件配置有加速度计和陀螺仪的特制手套，如图 2-1 所示，志愿者在空中持续写出所需的大写英文单词（每个字母长度约 20cm），并在完成一句话后手动停止。作者利用他人书写的单个字母样本，为每个大写字母建立共 26 个 HMM 模型。然后，分别通过打点标记和 SVM 切割出单个单词和其内部字母，在图 2-1 中，作者将单词‘a’与‘note’区分开来，并完成对内部字母的切割。接着，利用 HMM 字母模型，依次识别单个字母。最终，组合得到目标单词。




图 2-1 Airwriting 系统结构概览

三维空间大写英文字母识别实际包含一维冗余的信息，通常需要通过坐标轴变换和数据降维的方法将数据投影到二维平面，使手腕运动与字母笔画对应，这会造成时间浪费。同时，日常手写输入场景多为二维平面，三维空间手写识别应用空间十分有限。

(2) 二维平面手写识别方法。竖直平面上的书写场景：Arduser<sup>[31]</sup>在 LG Watch R 上开发了一款大写英文字母手写识别应用。实验者在竖直的黑板上写字，在写字过程中，整个手臂的运动和笔尖保持一致。图 2-2 中的(a)和(d)展示了志愿者佩戴手表写字的实验场景，图 2-2 中的(b)(c)(e)(f)则表明：将智能手表的设备坐标系转换成世界坐标系后，写字数据将不再受手表方向的影响，并且相同笔画的数据相位信息类似。因此，作者用动态时间规整（DTW）<sup>[32]</sup>方法对每个字母的原始数据进行分类，得到字母预测结果。

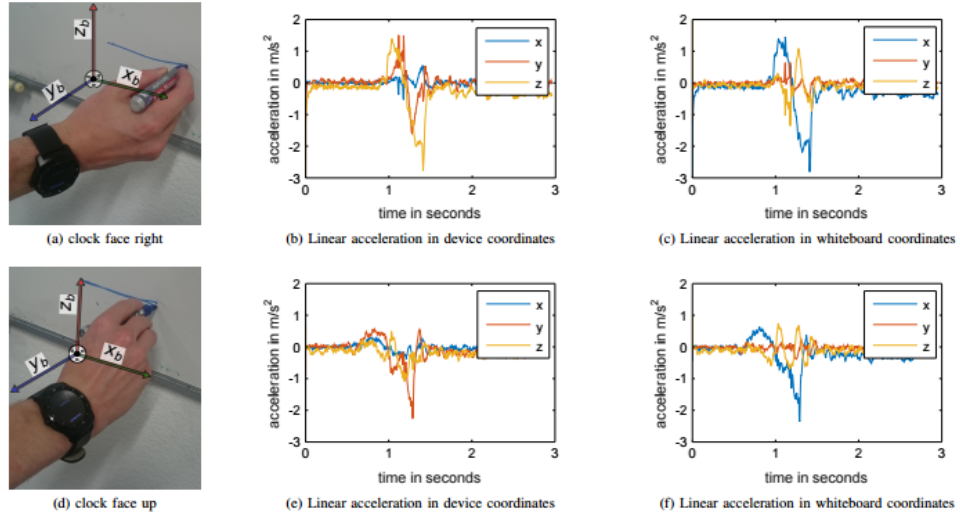


图 2-2 智能手表识别二维平面英文手写字母

竖直平面上的书写场景，多是借助字母本身简单的笔画构造或书写较大幅度来提高字母分类准确率。同时，单一的运动数据无法保证字母和单词的切割有较高精度，需要借助落笔动作或声音信号等辅助切割。

水平纸面上的书写场景：为进一步适应用户正常的写字习惯，Li 等人<sup>[33]</sup>提出了在纸面上书写小写字母的场景。文章中，用户每写完一个字母，需立即确定目标字母是否正确，并且需要大量的字母训练数据训练 DNN<sup>[34]</sup>模型。系统通过 DNN 分类器得到每个字母数据的预测结果，但由于单个字母的书写时长不同，导致收集的数据长度不一，对数据归一化等预处理需要额外时间花费。

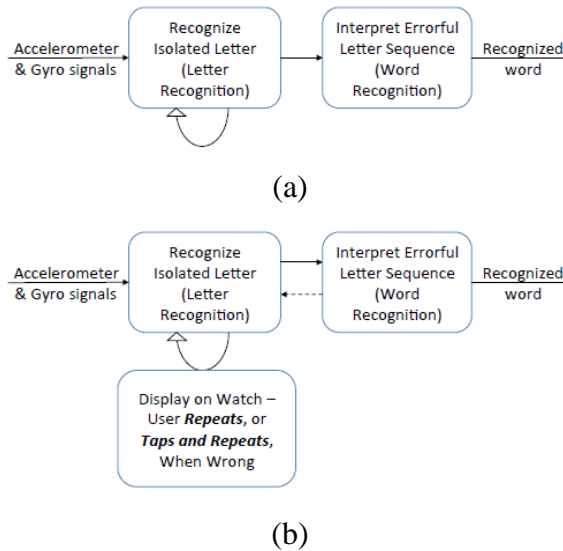


图 2-3 二维小写字母单词识别的两种方式。(a)之间将单词送入字典进行校正；(b)书写单个字母时不断校正错误的字母预测结果。

如图 2-3 所示，单词识别方法一般有以下两种形式，其一：将含有错误字母的序列直接送入字典中，通过字典纠正；其二：通过用户确认，将错误字母纠正，得到正确字母序列。

水平纸面上的书写场景相比竖直平面的书写场景更为接近用户日常写字习惯。然而，已有的方法，如 DNN，需要大量的字母训练样本，并且用户在每个字母确认的环节中需要耗费大量时间，无法完成流畅的书写活动。因此，本文需要进一步思考如何接近日常书写习惯，实现在水平纸面上的流畅、高效的手写识别方法。

## 2.2 基于智能设备的手写窃听方法概述

本节将讨论通过电子设备窃听输入信息的两种渠道：基于惯性传感器和基于声音的信息窃取方法，并详细介绍这两种渠道中具有代表性系统的设计思路。

(1) 基于惯性传感器的信息窃取。惯性传感器能记录大量用户手部运动信息，因此，有研究者尝试通过智能手表窃听用户输入信息。如图 2-4 所示，Liu 等人<sup>[26]</sup>通过加速度计确定佩戴智能手表的手指在键盘上的运动信息，预测用户的目标输入；对于全键盘只有一个智能手表的情况，如图 2-4(b)，则选择记录一只手的输入情况，对另一只手输入信息留空。最后，作者将所有单词预测结果送入字典，获得单词的正确拼写。本系统能窃听用户超过 50% 的击键信息，证明了




图 2-4 智能手表加速度计能够窃听用户击键内容。(a) POS 机输入密码；(b) 敲击键盘。

智能手表记录的用户敲击键盘时产生的加速度数据存在信息泄露风险。类似，Maiti 等人<sup>[27]</sup>也证明了智能手表加速度计记录的用户在触摸屏上的按键动作也具有泄密风险。

(2) 基于声音信号的信息窃取。论文 WritingHacker<sup>[28]</sup>表明：不仅是运动信息，用户写字时的声音信号也包含大量有用信息。如图 2-5 所示，作者根据用户



在书写大写字母产生的声音，用放置在一旁的手机麦克风，识别用户用标准笔画书写的大写英文字母。首先，26 个大写英文字母按照笔画数被分成三类；然后作者根据书写时，因为笔画数、笔画形态、书写时间等产生的区别，提取 MFCC 和频率特征等，区分出大写字母的基本笔画：横、竖、弧形等；通过设计 SVM 分类器得到字母预测结果；最后，用字典纠正单词的拼写错误，获得用户正确的手写文字信息。本系统在特定环境下能够还原用户 50% 左右的书写信息，证明用户书写时产生的声音信息存在信息泄露风险。




图 2-5 Writinghacker 系统架构示意图

## 2.3 相关技术简介

本节将介绍文中所涉及的主要应用平台和相关算法。

### 2.3.1 Android Wear

Android wear<sup>[35]</sup>是谷歌公司在 2014 年出品的一款全新智能平台，专门应用于智能手表。全球目前主要有三家公司拥有搭载 Android wear 平台的智能手表，他们分别是：LG Watch R，Moto 360 和三星 Gear live。在 Android Wear 第二代系统上，用户不仅可以体验系统自带的健康应用，通过调用内置传感器，自动记录用户的日常步行、骑行、热量消耗和心率信息等；同时还具备编程能力，对智能手表实现个性化的设置和更新。最重要的是，智能手表能够通过 Android Wear 连接上用户手机，配对完成后，将能实现与不同设备之间的信息交互，这对提高设备利用效率、丰富应用场景具有重要作用。

相比于普通手表，基于 Android Wear 平台智能手表的优势有以下三点：

- （1）免费开源的开发系统。所有开发者共同参与智能手表领域的开发工作，迅速丰富产品应用。
- （2）强大的传感器支持。相对于传统手表，智能手表将不仅仅用于装饰和查看时间。其中配置的加速度、陀螺仪、磁力计、心跳传感器、压力传感器等各种硬件设备能更准确记录用户的日常活动信息，帮助用户了解自己。
- （3）数据挖掘潜力。智能手表收集到的日常用户数据能为研究工作者提供十分有价值的数据，帮助人们分析日常生活中隐藏的健康、习惯等信息，这必将成为今后改善人类生活的重要一环。

随着 Android Wear 的产品升级,用户可以享受到更加智能的交互方式。表 2-1 展示了 Android Wear 在 2017 年末至 2018 年初的新尝试,表中不仅体现了开发者在不断尝试如何通过减少能耗增加待机时间,更在努力改进智能穿戴设备的消息查看机制和人机交互机制,使用户能够在小屏幕上尽可能完成必要的交互。因此,本文在智能手表上开发手写识别系统的尝试也是顺应广泛的用户需求,并能随着设备性能的提升而不断发展。

表 2-1 Android Wear 最近发型版本和新增功能

Version	Android base version	Release date	New features
2.7	7.1.1/8.0.0	Dec 2017	<ul style="list-style-type: none"> <li>Improved typefaces and font weights</li> <li>Complications now work with Talkback</li> <li>Text size of notifications adapts to message length</li> <li>Swipe down in Quick Settings to see connection type (Wi-Fi, Bluetooth, or mobile)</li> <li>Download progress notifications</li> <li>Recent App complication</li> <li>Better prevention of accidental side-swipe and long-press gestures</li> </ul>
2.8	7.1.1/8.0.0	Jan 2018	<ul style="list-style-type: none"> <li>Improved notification glanceability with a new layout which shows more of the user's message at a glance</li> <li>Darker background for better readability and less battery usage</li> </ul>
2.9	7.1.1/8.0.0	Feb 2018	<ul style="list-style-type: none"> <li>New notification preview complication which allows you to preview messages</li> <li>Improved glanceability in notification cards with longer titles</li> </ul>

### 2.3.2 隐马尔科夫模型 (HMM)

隐马尔科夫模型(Hidden Markov Model, HMM)<sup>[36]</sup>最初由 L. E. Baum 等科学家提出,是一种统计分析模型。因为隐马尔科夫模型能观测数据的隐藏逻辑转换状态,其在自然语言处理、手势识别<sup>[37]</sup>, 结构分析<sup>[38]</sup>以及生物信息等应用领域应用广泛。隐马尔科夫模型能够建立事物之间的各项联系,并用条件概率的方式预测后续事件发生的可能性。当输入一段有序测试数据时,隐马尔科夫模型能自动匹配该序列与模型的相似度,输出最佳预测值。

隐马尔科夫模型是一个由包含有限个状态数的马尔科夫链和随机函数集的双重随机过程<sup>[39]</sup>。该模型主要由五部分组成:

(1) 隐含状态  $H$ :  $H = \{H_0, H_1, H_2, \dots, H_N\}$ ,  $H$  是马尔科夫模型中无法通过直接观察得到的实际隐藏状态。

(2) 可观测状态  $O$ :  $O = \{O_0, O_1, O_2, \dots, O_M\}$ ,  $O$  是在马尔科夫模型中能够直接观察得到的状态, 与隐含状态  $H$  对应。

(3) 初始状态概率矩阵  $\pi$ : 描述了隐含状态  $H$  在模型初始时刻  $t=1$  时的概率矩阵。当  $t=1$  时,  $P(H_1) = p_1$ 、 $P(H_2) = p_2$ ,  $\dots$ ,  $P(H_N) = p_N$ , 初始状态概率矩阵表示为:  $\pi = [p_1 \ p_2 \ \dots \ p_N]$ 。

(4) 隐含状态概率转移矩阵  $A$ :  $a_{ij} = P(H_j|H_i)$ ,  $1 \leq i, j \leq N$ 。若  $t$  时刻的状态为  $H_i$ , 则当  $t+1$  时刻进入状态  $H_j$  的概率一般记为  $A = \{a_{ij}\}$ 。

(5) 观测状态概率转移矩阵  $B$ :  $b_{ij} = P(O_i|H_j)$ ,  $1 \leq i \leq M, 1 \leq j \leq N$ 。若  $t$  时刻的隐含状态为  $H_j$ , 则进入状态  $O_i$  的概率一般记为  $B = \{b_{ij}\}$ 。

最后, 模型还包括一条观测链和隐藏链, 若本文将模型用  $\lambda = (A, B, \pi)$  三元组标记, 则图 2-6 展示了一条隐马尔科夫模型  $\lambda$  的各部分结构对应关系。

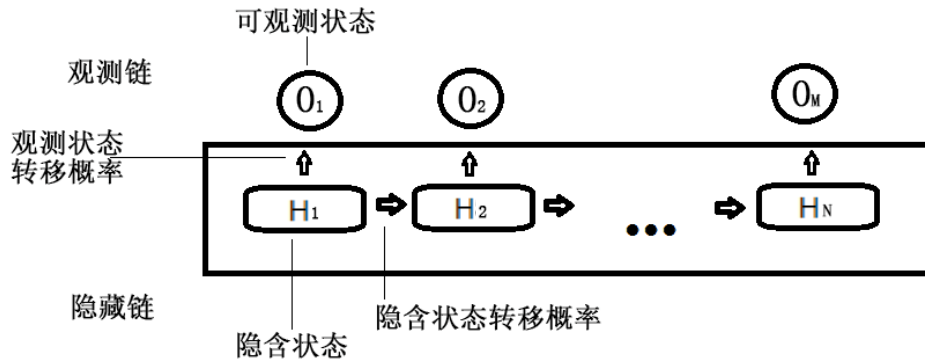


图 2-6 隐马尔科夫模型

### 2.3.3 支持向量机 (SVM)

支持向量机(Support Vector Machine, SVM)<sup>[40]</sup>是一种经典的机器学习模型, 在 20 世纪 90 年代由 Corinna Cortes 等人提出。支持向量机经常用于模式识别领域, 在分类问题和回归分析上也应用广泛。

根据不同种类的分类边界, 支持向量机可以分为: 线性可分和不可分两种。线性可分问题较为简单, 仅需在空间内能够区分两类样本的最佳边界, 使边界两端的垂直距离最宽。如图 2-7 所示, 图中分别展示了两种线性分类边界, 因左图中的边界宽度明显小于右图, 即左图区分两类样本的能力小于右图。因此, 本文选择右图作为最优分类边界线。




图 2-7 SVM 线性分类举例

然而，实际问题多为非线性可分。对于线性不可分数据，SVM 需要引入松弛变量提高分类准确率。首先，本文需要寻找一个从低维到高维的函数映射关系，使样本集在高纬度线性可分。然后，非线性可分问题被转化为线性可分问题，同理按照线性可分情况寻找最优分类超平面。

从低维至高维的函数映射需要核函数完成。核函数的种类不同，产生的映射也各不相同。目前常用的核函数包括：线性核、多项式核、径向基核（RBF）和 Sigmoid 核函数。

#### 2.3.4 随机森林（Random Forest）

随机森林（Random Forest）<sup>[41]</sup>是 1995 年由贝尔实验室的 Tin Kam Ho 提出的随机决策森林而来。随机森林有多个决策树共同组成，而每棵决策树均采用从上而下的递归方法，以信息熵为度量标准，根据信息熵递减最快的方法构造决策树，最终生成稳定的分类模型，其中决策树和随机森林的关系如图 2-8 所示。

随机森林的生成方式如下：

（1）若训练集样本大小为  $N$ ，对每棵树，随机且有放回地抽取训练集中的  $N$  个样本（Bootstrap sample 法），用于该数的训练集。用未抽到的样本集作为预测，评估该决策树误差。

（2） $M$  为样本集中提取出的所有特征个数。输入特征数目  $m$ ，其中  $m \ll M$ ，用于确定每个决策树上的节点决策结果。

（3）对每个节点，也就是一次分类结果，随机选择  $m$  个特征，计算最佳的分类方式，使样本信息熵最小。

（4）从所有决策树中随机选取若干个决策树组成随机森林，通过决策树输出结果决定整个随机森林输出结果。

由于随机森林在构造过程中引入多个随机变量，不仅避免了过拟合问题，也提高了整个模型的准确性，在现在的模式识别，分类问题上应用广泛。

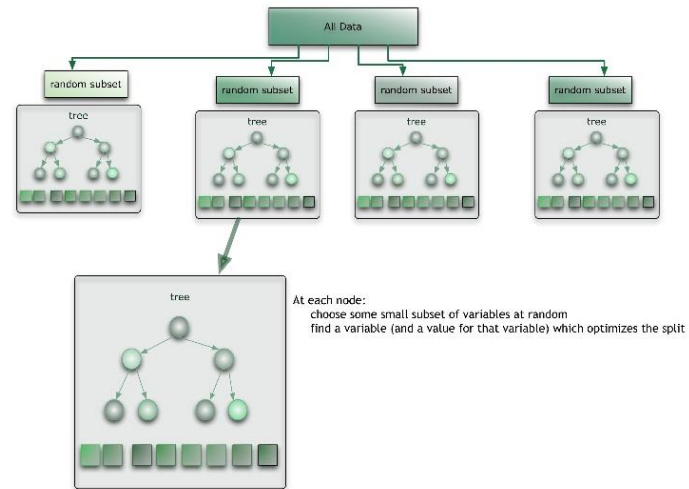


图 2-8 随机森林分类示意图

## 2.4 本章小结

本章主要介绍了基于惯性传感器的人机交互相关技术，包括 Android Wear、隐马尔科夫模型（HMM）、支持向量机（SVM）和随机森林（Random Forest）；然后概述了基于惯性传感器的手写识别方法和基于智能设备的手写窃听方法的科研发展和不足，进而引出本系统研究的必要性。

### 3 数据收集与分析

本章介绍应用智能手表上的惯性传感器进行手写相关数据的收集与分析工作。本章首先阐述如何用手表内嵌的惯性传感器记录用户手写英文小写字母的过程；其后，在 Matlab 下离线分析惯性传感器数据，通过可视化方法对数据序列中包含的异常值、噪音、笔尖与手腕运动差异和同一用户字母样本差异做详细分析。

#### 3.1 Android Wear 应用程序开发

本节将介绍如何在 Android Wear 平台下完成对智能手表数据收集应用的开发。与 Android 智能手机开发类似，本文采用 Google 公司的 Android Studio 开发工具，开发工具包版本为 JDK 1.7.0\_21。

图 3-1(a)展示了本系统的工程架构图。其中，src 目录内为工程源代码，内部 Waving 包主要实现界面设计模块，负责程序与用户的交互工作；util 包内涉及时间戳获取、文件读写、坐标系变换，以及一些工程用到的常量定义。两个工程包分别面向用户和底层，分工明确，使用户能够更快熟悉数据收集应用程序。在 res 目录下主要存放系统的资源文件，包括 drawable、layout、mipmap、values 和一些外部工具包，程序界面用到的相关图片、布局、算法等都是通过 res 内的文件完成。AndroidManifest.xml 是全局配置文件，在这里能够完成各种应用所需监听器的注册，声明文件读写权限等。

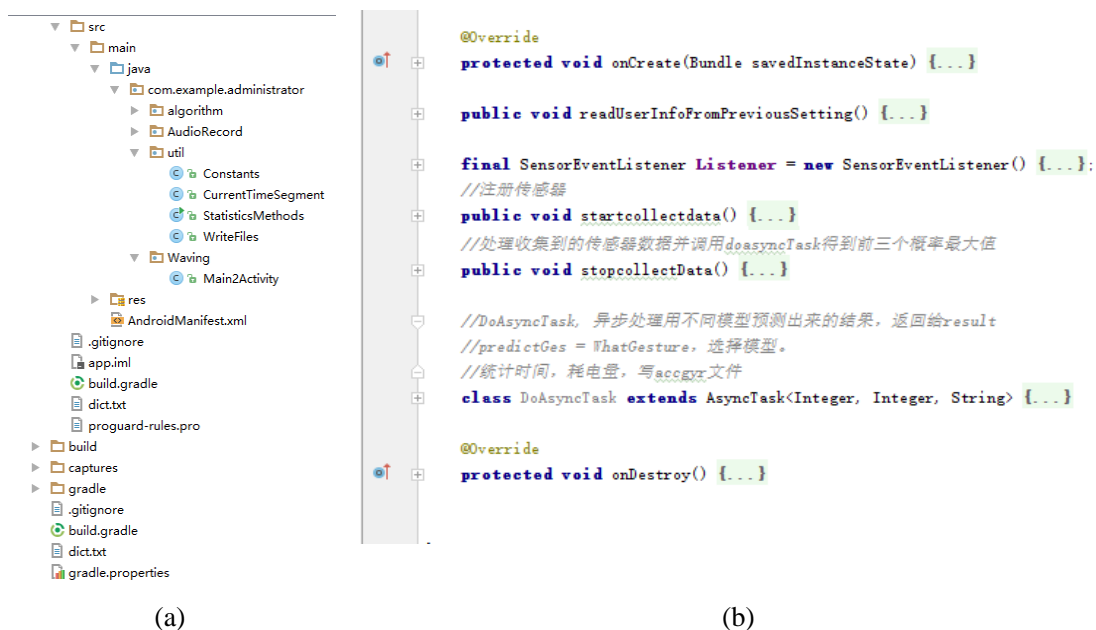


图 3-1 系统工程展示。(a) 工程架构图；(b) 主要功能函数。

图 3-1(b)则集中展示了本应用的主要函数：`SensorEventListener()`负责注册传感器；`startcollectdata()`完成赋值和监听，使系统正常工作；`stopcollectData()`主要负责传感器数据存储，并暂停所有数据收集工作，等待下一次开始；`onDestroy()`销毁所有进程，释放应用所占空间。

本文将在下一节详细介绍用户交互界面和数据采集实验的设计和实施。

## 3.2 实验设计与手写动作数据收集

实验设计和数据收集工作是基于惯性传感器的人机交互领域的前提和基础。本文的实验设计与数据收集工作在 Android Wear 平台的 LG Watch R 下完成的，接下来将对实验设计和数据收集环节分别介绍。

### 3.2.1 采集手写动作实验设计与数据收集

为了更好地捕捉手腕运动信息，本文招募了 10 名志愿者，年龄在 21 至 25 岁之间。志愿者需将手表佩戴在用于写字的手腕一侧，位置尽量靠近腕关节处，以获取全面的腕关节活动信息；表带采用较软材质，让手表完全贴合手腕，以便捕捉写字时手腕的精确运动数据。手表佩戴方式如图 3-2 所示。



图 3-2 手表佩戴方式

收集数据的界面如图 3-3(a)所示，在开始时采集数据前，每位志愿者点击“Collecting”文字下的第一条复选框“letter name”，此时，页面跳转至图 3-3(b)，选项包含 ‘A’ - ‘Z’，共 26 个字母命名的选项，志愿者从中随机选择一个唯一代表本人的字母，按下“OK”键，然后回到图 3-3(a)，此后，传感器收集到的数据将会存储至手表中那个以“字母+本地时间”命名的文件夹下。图 3-3(c)展示志愿者按下右侧‘collect’按钮后的界面，此时，手表开始正式记录不断产生的惯性传感器数据。当志愿者完成一次完整的数据收集实验后，按下‘stop’按钮，结束数据收集工作，手表自动将记录结果保存至指定内存空间。智能手表的



采样频率为 200Hz，记录的有效惯性传感器数据包括：时间戳、世界坐标系下的




图 3-3 数据收集系统界面

加速度传感器数据和陀螺仪数据。

志愿者被分为独立的 A, B 两组, 每组由 5 名成员构成。A 组成员每人在印有标准四线格的纸张上按顺序抄写小写英文字母 ‘a’ 至 ‘z’, 具体笔画见图 3-4。其中, 在开始和完成单个字母书写时, 均需要将笔短暂静止于纸面, 以便准确找出写字区间(字母间连笔不在本实验考虑范围内), 顺序书写一次 ‘a’ 至 ‘z’ 记为一次完整实验数据采集。每位志愿者每天需要完成至少 20 组实验, 共持续 6 天。另外, A, B 两组成员均需要抄写两组来自不同体裁文章的段落各一次, 第一段文章为小说《老人与海》的第一段, 共计 101 个单词; 第二段文章为论文 WritingHacke<sup>[28]</sup>的 Conclusion 段落, 共计 100 个单词, 书写单个字母的方法与上文类似。需要注意的是, B 组人员全程未知晓和参与 A 组字母收集的实验, 且两段节选文字中的特殊名词和字符均已删除。两段文字内容如图 3-4 所示。

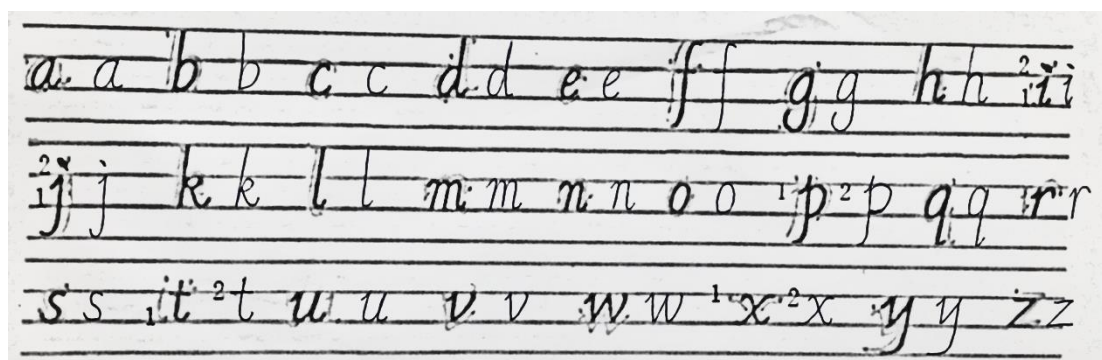


图 3-4 标准英文小写字母手写体展示



he was an old man who fish alone in a skiff in the stream and he had gone eighty-four day now without taking a fish in the first forty day a boy had been with him but after forty day without a fish the boy parent told him that the old man was now definite and finally which is the worst form of unlucky and the boy had gone at their order in another boat which caught three good fish the first week it made boy sad to see the old man come in each day with his skiff empty.

(a)

in this paper we present a prototype system which explore the possibility of audio-based eavesdrop on handwriting via the mobile device based on letter cluster we designed the component of input detector dictionary filter and word recognizer which enable the mobile device to record and recognize a victim handwriting make it possible for an attacker to violate a victim privacy by keeping a mobile device touch the desk be used by the victim the experiment result show that under certain condition the accuracy of word recognition reach which reveal the danger of privacy leakage through the sound of handwriting.

(b)

图 3-5 段落数据采集内容。(a)《老人与海》第一段；(b)论文“conclusion”部分。

### 3.3 观察惯性传感器数据

为了寻找合适的方法实现手写识别和手写窃听系统，本文首先需要对采集到的原始数据进行观察分析。当志愿者书写规范小写英文字母或单词时，智能手表实时记录加速度和陀螺仪传感器数据。本文将加速度序列表示为  $a = (a_1, a_2, \dots, a_n)$ ，其中向量  $a_i = [a_x(i), a_y(i), a_z(i)]^T$  表示加速度传感器在第  $i$  个采样点处的加速度三维坐标值， $n$  表示整个写字过程中加速度序列的总长度。同理，本文将陀螺仪序列对应的表示为  $g = (g_1, g_2, \dots, g_n)$ ，其中向量  $g_i = [g_x(i), g_y(i), g_z(i)]^T$  表示陀螺仪在第  $i$  个采样点处的角速度三维坐标值， $n$  表示整个写字过程中陀螺仪序列的总长度。

#### 3.3.1 异常值分析

商业用传感器对精度要求不高，硬件设备不够精密，易出现异常值，影响后续数据处理。如图 3-6 示，在  $a_i = [a_x(i), a_y(i), a_z(i)]^T$ ，其中  $i=175$  位置周围出现一组采样点异常，该采样点数值明显高于周围数据。而在实际书写过程中，不可能发生加速度在短期内的急剧变化。因此，本文需要通过异常点（如  $i=175$ ）周围的正常数据校正该异常值。




图 3-6 惯性传感器采集的数据中出现异常值

### 3.3.2 噪音分析

噪音同样是商业用传感器较为常见的问题。当水平静止放置智能手表时，加速度和陀螺仪数值会在 0 附近波动，而不是静止，这是由于常见的内嵌于智能设备中的商用加速度传感器多为压电式加速度传感器，加速度数值的改变取决于压电元件上的电压变化，并依此获得加速度数值。当设备本身的精度不高，电压波动明显时，加速度数值便会存在误差，随着时间的推移，误差逐渐累积，和真实值差别将进一步扩大。类似的，陀螺仪传感器也会携带噪音，随着时间积累，误差不断扩大。

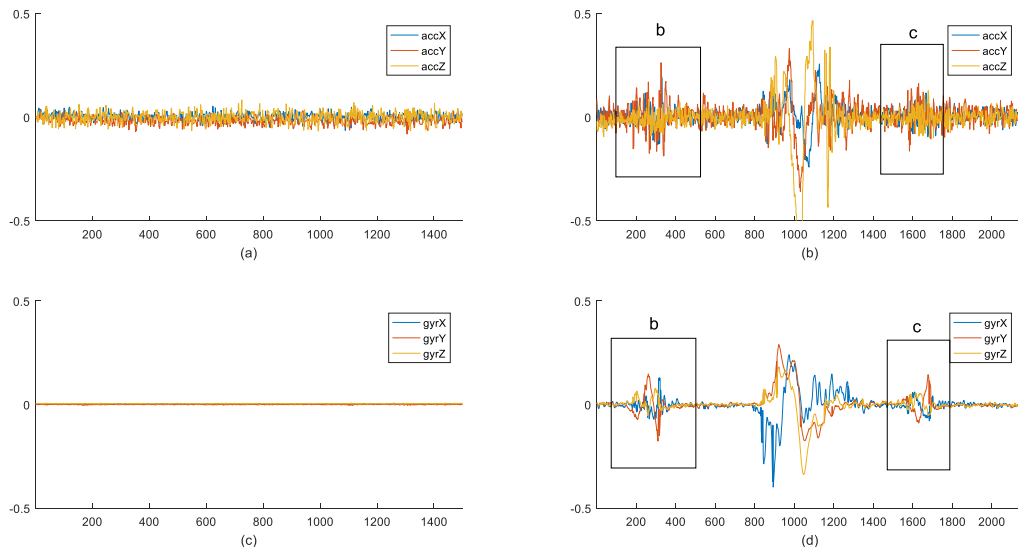


图 3-7 静止和写字时加速度和陀螺仪数据对比。(a)静止时加速度数据；(b)书写 b 和 c 时加速度数据；(c)静止时陀螺仪数据；(d)书写 b 和 c 时陀螺仪数据。

图 3-7 向本文展示了某一志愿者在书写字母‘b’和‘c’时的加速度和陀螺仪传感器数据，在图 3-7(b)和图 3-7(d)中分别用矩形标记出来。例如，字母 b 的有效区域为  $i=100$  至  $i=500$  间的所有采样点，相邻两侧的约 100 个采样点为笔尖

静止不动时的数据，其波动范围分别与手表水平放置于桌面时的数据相似，如图 3-7(a)和图 3-7(c)所示。本文发现：在笔尖静止不动时，加速度和陀螺仪依然会在 0 附近上下波动，且加速度计在静止时刻的噪音明显高于陀螺仪。此外，写字状态下的手腕运动幅度较小，因此本文无法忽略噪音对字母识别的影响。

为了寻找每个传感器上噪音所在的具体频段，本文选取一组训练数据样本作为示例进行快速傅立叶变换，如 3-8 所示。从对加速度和陀螺仪数据做快速傅里叶变换（FFT）的结果来看，能量较高的频率主要集中在 1Hz 到 50Hz 的低频区域，如图 3-8 所示，对应的是这组数据中的写字行为。因此，本文选择频率合适的低通滤波器能较好的消除智能手表产生的噪音，并且保留志愿者在书写字母时的运动轨迹。

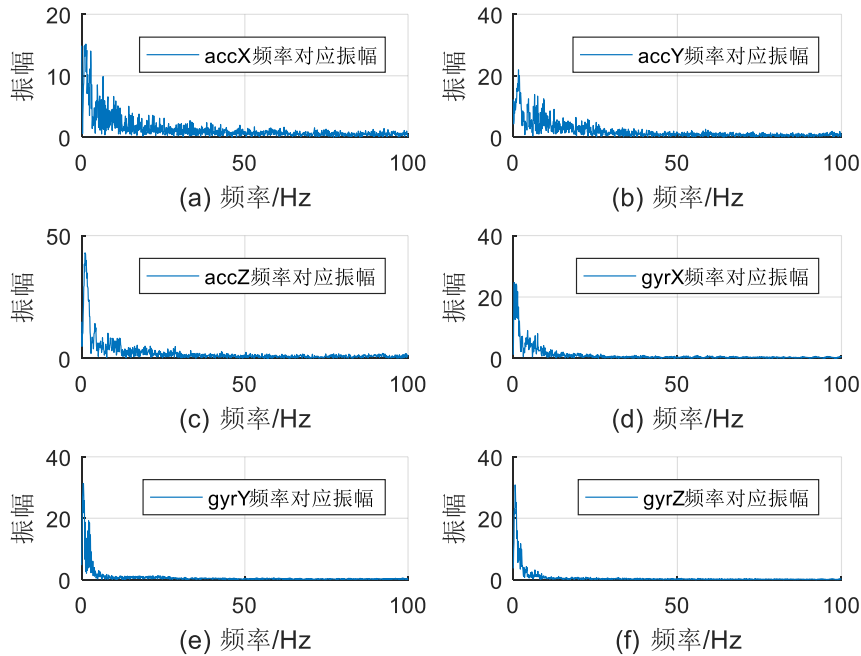


图 3-8 数据 FFT 后各坐标轴不同频率对应幅值。(a)加速度计 x 轴上的数据；(b)加速度计 y 轴上的数据；(c)加速度计 z 轴上的数据；(d)陀螺仪 x 轴上的数据；(e)陀螺仪 y 轴上的数据；(f)陀螺仪 z 轴上的数据。

为确定写字行为所在的具体频段，本文分别选择通带在(1,10)，(1,30)和(1,60)的滤波数据与原始数据进行对比。角速度数据中的波峰与波谷能直观反映手腕在不同方位的转动，图 3-9(a)和图 3-9(b)的数据较为平滑，其中，图 3-9(b)损失的信息较少，图 3-9(c)的数据不够平滑，仍有可能存在噪音。综合考虑平滑效果和保留有效信息，本文选择低通滤波器的通带为 1Hz 到 30Hz。

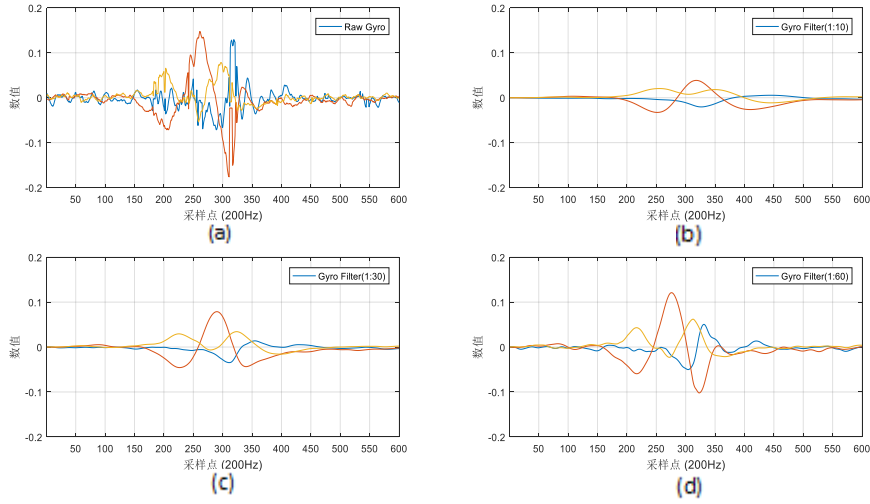


图 3-9 陀螺仪数据选择不同通带频率的滤波结果。(a)陀螺仪原始数据；(b)1Hz 到 10Hz；  
(c)1Hz 到 30Hz；(d)1Hz 到 60Hz。

### 3.3.3 笔尖与手腕运动差异

由于运笔和姿势的差异，不同用户在书写完全相同的字母时，传感器获得的手腕运动数据不尽相同，这导致用于直接跟踪手腕运动的时域和频域特征不能同时在不同用户间取得较好的分类效果。

为比较手腕运动轨迹在不同用户间的差别，本文选取 4 名志愿者，每人在同一桌面，相同位置，临摹同一字母‘b’。本文对获取到的加速度数据和时间戳二重积分，得到手腕运动的三维轨迹。公式 3-1 表示用户在 $t_1$ 到 $t_n$ 时间段内，通过智能手表下世界坐标系中的各坐标轴的加速度 $a = [(a_x, a_y, a_z)]^T$ 和时间戳二重积分得到的位移信息， $J(t)$ 表示位移随时间变化的函数。

$$J(t) = \iint_{t_i}^{t_1} a t dt \quad , \quad i = 1, 2, 3, \dots, n \quad (3-1)$$




图 3-10 不同用户书写同一字母‘b’的手腕运动三维轨迹。

如图 3-10 所示，每一条曲线代表不同用户在书写字母‘b’时的手腕运动轨迹，通过对 4 组序列进行观察分析，本文发现：不同用户在书写完全相同的字母时的手腕活动存在较大差异，笔尖与手腕运动的对应关系因人而异。因此，简单地跟踪和提取手腕运动信息将无法实现不同用户的手写字母识别。

### 3.3.4 同一用户字母样本差异

现实生活中，用户无法完全重复自己的上一次动作，这导致即使用户完全按照相同的笔画临摹字母，得到的手腕运动轨迹也存在差别，这是由写字速度、力度和初始位置等因素的改变引起的。

图 3-11 展示了同一志愿者在同一位置临摹字母 b 时的 4 组角速度数据滤波结果。通过对比(a)和(b)本文发现：同一时间段内三轴的极值相对位置存在差异，也就是说在完成同一笔时的发力方式不同；对比(c)和(d)时，发现各坐标轴上数据的极值各不相同，这是由写字速度不同引起的。

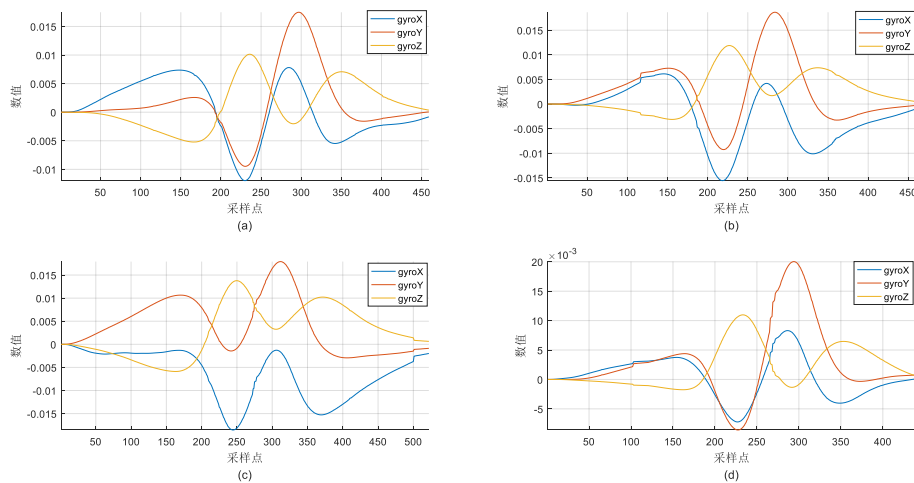


图 3-11 同一志愿者在同一位置临摹字母 b 时的 4 个角速度数据样本。

因为上述差异可能会造成相同字母被错分成多类的情况，为减少这种情况发生，提高分类准确率，本文将数据做归一化处理，使所有数据大小在同一区间，避免因写字速度产生的差异，本文将在下一章进行详细介绍。

### 3.3.5 小写英文字母笔画设计冗余

论文 Touch-Typing<sup>[42]</sup>指出：26 个英文字母在设计过程中便存在笔画冗余，这使某些字母的笔画完全包含在另一个字母中，尤其在手写时更易混淆。如下图 3-12 所示，字母‘r’，‘d’和‘q’的手写体分别极易与‘v’，‘a’和‘g’的字形混淆，因为它们只需由手腕完成相同方向的旋转便可写成。虽然本文规定志愿者皆遵循标准手写体笔画，但是在手腕运动过程中仍较难分别细小的运动差异。



图 3-12 几种容易混淆的手写英文字母展示。

### 3.4 本章小结

本章详细描述了实验数据的采集过程。分析收集到的数据后本文发现，原始加速度和陀螺仪数据存在异常值和噪音，并且在本文的手写动作识别中无法被忽略。同时，重复书写的不稳定性，不同人的差异性和笔画设计的冗余增加了字母分类的难度。本文需要进一步提取运动数据中稳定的特征，实现手写识别和窃听系统功能。

## 4 手写识别系统

随着可穿戴电子设备的普及，本文提出通过智能手表的惯性传感器识别用户手写英文字母的手写识别系统。该系统无需其他昂贵的辅助设备支持，符合用户手写习惯，同时可以作为小屏幕电子设备的输入选择。

本章将重点针对小幅度动作切割问题和手写英文字母识别问题，提出解决方案，详细介绍手写识别系统的设计架构、数据切割部分以及特征筛选部分，通过寻找能够反映不同字母结构的稳定特征，降低字母识别准确率因为用户初始状态、写字速度等带来的影响，并对手写识别系统的性能进行试验与评估。

### 4.1 系统概述

志愿者将智能手表佩戴在用于写字的手腕关节处，手写识别系统能自动切割出有效写字部分，通过先提前建立好的字母分类模型，识别该用户书写的单个字母，然后通过字典修正字母拼写，还原正确单词。

本节主要对手写识别系统的设计架构进行总体介绍，系统包含：数据收集模块、数据预处理模块、字母及单词切割、特征提取、字母识别和单词识别六大模块。各个模块结构与联系如图 4-1 所示。



图 4-1 手写识别系统结构示意图。

(1) 数据收集模块：本系统采用 Android Wear 平台下的 LG Watch R 智能手表，设计并实现了数据收集模块。设备的采样频率为 200Hz，A 组的共 5 名志愿者参与了本次实验。为获得训练数据，每名志愿者被要求在印有四线格的 A4 纸上用标准英文手写体按字母排序依次抄写 ‘a’ 至 ‘z’ 26 个英文字母，每天 20 组，连续 6 天。同时，每位志愿者需要按照标准手写体格式分别抄写两段节选文章，用于单词识别研究。手表惯性传感器产生并记录相应的时间戳、加速度和陀螺仪数据，保存在手表内存空间。

(2) 数据预处理模块：获得惯性传感器数据后，本文首先对数据进行异常值处理和低通滤波消除噪音，尽可能消除因传感器本身精度问题带来的误差。然后，根据数据分析结论，对陀螺仪数据归一化处理。

(3) 字母及单词切割：分别处理实验获得的两类训练数据：含有 26 个有序英文字母的手写样本和两篇文章段落节选。利用用户写字和其他状态下的特征差异，标记单词边界，并借助写字规则，继续分离单词中的各个英文字母。

(4) 特征提取：观察切割后的单个字母样本的加速度和陀螺仪数据，枚举相关时域、频域以及相位信息，筛选出能够反映字母本身结构的稳定特征。

(5) 字母识别：使用本人字母训练样本，用随机森林分类器，为每位志愿者的所有字母建立分类模型，评估各个志愿者的字母分类准确率和模型鲁棒性。

(6) 单词识别：用志愿者本人的字母分类模型识别该志愿者的摘抄内容。根据切割模块确定的单词边界，将字母识别结果组合并送入字典纠正拼写错误，获得正确的单词预测结果。

## 4.2 数据预处理

虽然，笔尖运动能清晰地区分横、竖、弧和点等字母基本笔画，但驱动笔尖运动的手腕运动却不明显。从上文数据分析结果可知，本文必须对原始传感器数据进行异常值处理和降噪处理，才能在采样序列中分离出写字部分，然后再识别字母和单词。

### 4.2.1 异常值处理

商业用惯性传感器在产生采样数据时难免存在异常点。在本文实验过程中，每一组实验几乎都包含异常区域，每个区域均由离散个明显高于或低于周围采样点的数据组成。因为异常点在数据集中分布较离散，且所占比例较小，本文采用拉依达准则<sup>[43]</sup>来识别和剔除异常值。

本文认为收集到的传感器数据遵从高斯分布模型，拉依达准则可以从该模型序列中判断是否存在异常值。以加速度计  $x$  轴上的数值为例：在某一时间段内，加速度计收集到的加速度  $x$  轴数据表示为  $a_x = \{a_{x(1)}, a_{x(2)}, \dots, a_{x(n)}\}$ ,  $a_{x\_mean}$  表示  $a_x$  序列的算数平均值， $\sigma$  为  $a_x$  的标准误差。如公式 4-1 所示，若存在  $a_{x(i)}$ ，其中  $1 \leq i \leq n$ ，使得  $|a_{x(i)} - a_{x\_mean}| > 3 * \sigma$ ，则认为  $a_{x(i)}$  是在该序列中含有较大误差值的坏值，应予以剔除， $A_x$  为  $a_x$  序列内所有异常值组成的集合。同理，遍历加速度计的其他两加速度坐标轴数据和陀螺仪的三轴数据，得到异常值集合  $A_y$ ,  $A_z$ ,  $G_x$ ,  $G_y$ ,  $G_z$ 。

$$A_x = \{a_{x(i)} \mid |a_{x(i)} - a_{x\_mean}| > 3 * \sigma, \quad i = 1, 2, 3, \dots, n\} \quad (4-1)$$

为保证加速度和陀螺仪传感器数据在同一时间上的对应关系，异常点需要用合理数值替代，而非直接删除。本文认为人在写字过程中，手腕运动是流畅的，所以，惯性传感器的数值变化也应较为平滑。在发现加速度  $x$  轴曲线上的异常点



后，本文分别前后寻找离异常点最近的 5 个正常数值，用集合 $a_{xl}$ ， $a_{xr}$ 标记，再取 $a_{xl}$ 和 $a_{xr}$ 的算数平均数替代原先异常值。同理，依次修正其他坐标轴曲线上的异常值数据。

#### 4.2.2 低通滤波器

由于写字时的手腕运动十分微小，惯性传感器产生的噪音会严重影响数据的可视化以及字母分类准确率，因此本文需要通过滤波消除噪音。

常用的滤波器结构有巴特沃斯滤波器<sup>[44]</sup>，切比雪夫滤波器<sup>[45]</sup>和贝塞尔滤波器<sup>[46]</sup>。贝塞尔滤波器因其相位线性的特性，专门用于音频处理，因此在本文中不再讨论。巴特沃斯滤波器在通带内，滤波器放大倍数基本不随频率变化改变，所以滤波后的曲线较为平缓，但在干扰频率和有效频率接近时，无法较好区分边界。切比雪夫滤波器可以解决干扰频率和有效频率接近的情况，但因其过渡带陡峭，且滤波器的放大倍数会随频率改变，因此较难保持通带频率内的有效数据特征。图 4-2 展示了两种滤波器在处理同一数据后的效果图，图 4-2(a)是某用户书写字母 b 时的原始角速度数据；图 4-2(b)为用切比雪夫滤波器处理后的结果；图 4-3(c)为巴特沃斯滤波器的滤波结果。对比可知，x 轴曲线的角速度序列在曲线波峰和波谷位置时，(c)较(b)更为平滑，而平滑的曲线能更加直观观察字母笔画和相位特征。因此，在提取相位相关特征时，本文选取巴特沃斯低通滤波器对陀螺仪数据进行预处理。




图 4-2 (a)字母 b 的原始陀螺仪数据；(b)通带频率在 1-30Hz 的切比雪夫滤波器滤波结果；  
(c)通带频率在 1-30Hz 的巴特沃斯滤波器滤波结果。

### 4.3 字母及单词切割

字母及单词切割是本文的难点之一。在一段完整的手写采样序列中，因为动作幅度小，很难直接找到单个字母的具体起止位置。前人的研究很少涉及小幅度

动作切割和小写英文字母切割问题,这通常需借助笔敲击纸面的动作或者声音辅助切割<sup>[47,48]</sup>。本章将详细介绍如何定位及切割单个字母的具体步骤。另外,因为数据采集的方式和目的不同,本文的切割方法将分为字母切割和单词切割两部分进行阐述。

#### 4.3.1 字母切割

A 组的志愿者按要求佩戴智能手表,根据字母顺序,依次书写‘a’到‘z’ 26 个小写英文字母,作为一组训练数据。本文从每组数据中分离出单个字母作为训练集,用于构建小写字母分类模型。然而,写字引发的手腕活动幅度较小,与其他动作(如静止)的边界并不明显,如何将单个字母从一组数据中分离出来,成为字母切割的一大难题。

在传感器选择方面,本文选取了精度更高的陀螺仪数据寻找字母切割位置。同时,角速度的变化能反映手腕旋转的幅度和方向,这些特征可以作为切割字母的重要指标。




图 4-3 字母切割示意图。(a)某志愿者字母训练数据预处理后陀螺仪数据节选;(b)陀螺仪数据相位和的平滑结果。

本文将通过图 4-3 阐述数据预处理流程。图 4-3(a)展示了某志愿者的一组 26 个字母手写数据中的一段。图中,第一个矩形框内标记的是小写字母‘a’的手腕角速度变化,其后紧随一小段静止时间,然后是手腕自然移动到下一个写字位置产生的角速度变化。第二个矩形框内的数据为小写字母‘b’的手腕运动运动轨迹,依次类推。从图 4-3(a)中可以看出:无论是写字还是手腕的局部移动,三轴陀螺仪数据均会产生较大幅度的波动,而静止时,角速度数据在 0 附近波动,且较为稳定。利用角速度在运动和静止时间段内的振幅高低,本文可以找出写字与手腕平移两种运动行为的具体位置,为下一步继续确定写字区间做准备。

首先，利用手腕静止和运动时在振幅上的差异，如公式 4-2 所示，本文对每一采样点上的三轴陀螺仪数据取绝对值后求和；然后，本文采用窗口大小为 100，步幅为 10 的滑动窗口对上述振幅相关数据平滑处理；最后，本文得到一组较为平滑的波峰，如图 4-3(b)所示。其中，每一个波峰对应一次写字或手腕平移动作，而如何进一步区分写字和手腕平移动作将在下文详细介绍。

$$G_i = (|g_{x(i)}| + |g_{y(i)}| + |g_{z(i)}|), \quad i = 1, 2, 3, \dots, n \quad (4-2)$$

在公式 4-2 中， $G_i$  为每个采样点对应的陀螺仪振幅之和， $|g_{x(i)}|$ ， $|g_{y(i)}|$ 和 $|g_{z(i)}|$ 分别是陀螺仪各坐标轴上每个采样点对应的振幅绝对值。4-3(b)展示了用 Matlab 的 findpeaks 工具箱找到的所有波峰位置。由实验数据得知，手腕移动的振幅普遍高于手写动作，因此，本文设定固定阈值  $\tau_1$  初步将写字和手腕平移这两类动作区分开。然而，不乏个别手腕移动的峰值过低，或手写动作的峰值超过阈值的情况，本文需要根据用户书写习惯等其他特征对这两种运动进一步区分。根据志愿者书写规律，本文得到以下两个限制条件：

(1) 两次相邻手腕平移动作对应的波峰之间至少应包含 600 个采样点，这是由于两次手腕平移动作中间必然存在一次写字行为和短暂停顿，本文根据 A 组数据中笔画最简单的字母 c 的书写时间设定该数值。反之，若存在两次连续手腕平移动作对应的波峰间少于 600 个采样点，则认为峰值较小的波峰不是手腕平移运动，应舍去；

(2) 两次相邻手腕平移动作对应的波峰间最多不超过 1200 个采样点。如果存在两次连续手腕平移动作，且相邻波峰间大于 1200 个采样点，则有可能遗漏一次手腕平移动作。尝试在两波峰中间寻找一个最大波峰，并将其定义为一次手腕平移动作。

根据数据采集规则可知：两个相邻手腕移动对应的波峰之间，必定存在一次写字动作。因此，本文定义：从第一个已标记波峰到下一个波峰间最低点位置为写字的起始位置；下一个手腕移动波峰与前一个波峰间的最小值记为该字母结束位置。另外，字母‘a’和字母‘z’所在位置因为不存在第一次和最后一次手腕平移，本文分别将手腕平移产生的峰值位置用数据的第一个点和最后一个点代替。以图 4-3(b)中的字母‘b’为例，本文在确定相邻两次手腕平移动作位置‘2’和‘5’后，将‘2’与‘3’间的最小值作为写字起始位置，将‘4’与‘5’间的最小值作为写字结束为止。因为一组采样数据只包含 26 个字母，本文没有手动为每个字母位置打标记，只能依赖实验规则和不同峰值找到字母位置。当且仅当切割后的写字区域有 26 块时，本次数据采集才有意义（当不足或超过 26 个字母时，系统无法自动标记每个字母，因此本组数据作废）。

### 4.3.2 单词切割

与字母切割不同的是，单词切割需要首先找到单词的边界。图 4-4(a)中可以发现，从一个单词结束到下一个单词间，用户需要将手腕抬离纸面。因此，在抬腕的一瞬间，加速度  $z$  坐标轴数据会发生明显变化。本文在对整个加速度的  $z$  坐标轴求能量值后，便可以更清晰的观察到抬腕动作，能量计算公式如公式 4-3 所示。

$$E_i = (a_{z(i)})^2, \quad i = 1, 2, 3, \dots, n \quad (4-3)$$

其中， $n$  为数据总长度， $a_{z(i)}$  为加速度计  $z$  坐标轴曲线上各采样点对应的值，

$E_i$  为  $a_{z(i)}$  的能量值。

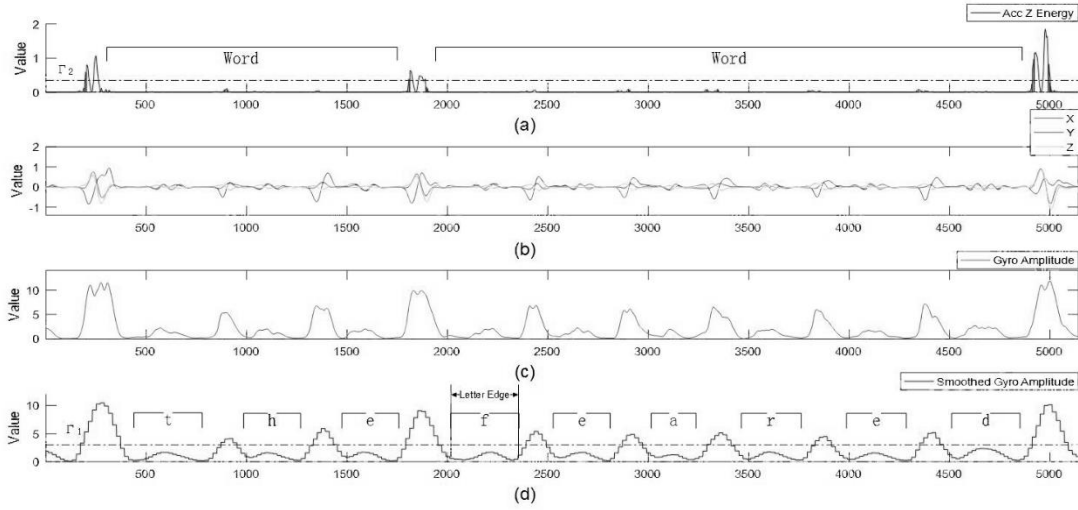


图 4-4 (a)通过阈值  $\tau_2$  切割单词；(b)预处理后的陀螺仪数据；(c)计算陀螺仪振幅之和；(d)

通过阈值  $\tau_1$  切割字母。

如图 4-4(a)所示，阈值  $\tau_2$  能很好地找到单词边界。图中，两个单词的前后位置都存在一段数据明显高于阈值  $\tau_2$ ，因此，本文将小于  $\tau_2$  的两相邻区域定义为某单词的有效区域。

在确定了单词的边界之后，本文进一步寻找字母的边界。由于加速度数据精度的限制，在记录小幅度动作时误差太大，不易分割，因此本文选择更精确的陀螺仪信号处理字母切割问题。

图 4-4(b)显示了预处理后的陀螺仪信号。经过公式 4-2 计算振幅绝对值之和，本文得到图 4-4(c)所示结果。然后，选取滑动窗口大小为 100，步宽为 10 的滑动窗口对图 4-4(c)中数据平滑，获得图 4-4(d)结果。通过从字母切割中获得的

阈值  $\tau_1$ ，本文进一步得到每个单词内部的字母切割位置。图 4-4(d)中，用矩形标记出的部分为手写字母 f 的有效区域。

接下来的切割方法类似上节字母切割部分，将单个单词认为一组完整的字母数据样本，利用志愿者书写字母时的习惯，我们可以获得单词内部每个字母的具体边界。

## 4.4 特征提取

前人在动作识别的研究工作中多是直接提取原始数据中的时域和频域特征，但是这些特征对区分对幅度小、轨迹差别不明显的动作不具备较好的分类效果。本节将介绍用于区分 26 个手写英文小写字母的特征，包括加速度和陀螺仪传感器相关时域、频域及相位特征，并对特征进行筛选，在保证字母分类模型鲁棒性的前提下降低特征冗余。

### 4.4.1 特征枚举

本文分别提取了陀螺仪频率特征、相位特征和加速度频率特征，用于 26 个小写英文字母的分类。

(1) 陀螺仪频率特征。字母的形态直接决定手腕转动的轨迹，而陀螺仪频率特征能够反映手腕转动的速度变化，进而区别不同字母间差别。通过快速傅立叶变化 (FFFT)，本文得到不同样本的各个坐标轴曲线上的角速度频率信息，作为提取频率特征的输入信号。

A. 陀螺仪各坐标轴曲线不同频率幅值：直接将原始数据 FFT 变换后的结果作为特征并不能达到好的分类效果，Hong<sup>[49]</sup>等人选取了不同频率对应的幅值作为特征来提高分类准确率。同理，本文选取了陀螺仪三个坐标轴曲线在 1Hz 到 25Hz 对应的幅值作为特征，用  $\{f_1, f_2, \dots, f_{75}\}$  表示。这类特征能较好的反映写字运动的周期变化，在区分局部结构差异较大的字母时表现较好。例如：图 4-5 中， $f_{29}$  和  $f_{57}$  能够区分大多 {b,m,q,t} 字母样本， $f_{51}$  和  $f_{54}$  能够区分大多 {e,r,g,l} 字母样本。

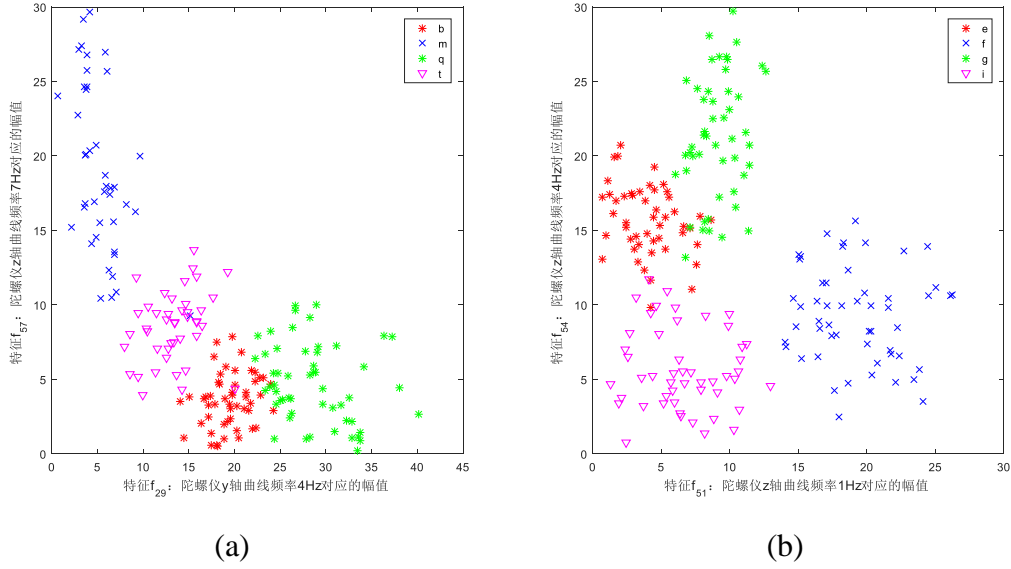


图 4-5 特征枚举。(a)特征 $f_{29}$ 和 $f_{57}$ 对字母集合{b,m,q,t}的分类效果；(b) 特征 $f_{51}$ 和 $f_{54}$ 对字母集合{e,r,g,l}的分类效果。

**B. 陀螺仪各坐标轴信息熵：**信息熵表示该坐标轴曲线上幅值的分布情况，从而反映用户在写字时的速度变化。陀螺仪各坐标轴曲线频率幅值的信息熵<sup>[50]</sup>特征分别用 $f_{76}$ ， $f_{77}$ ， $f_{78}$ 表示，计算公式如公式 4-4 所示。

$$Q = E[-\log p_i] = -\sum_{i=1}^n p_i \log p_i, \quad i = 1, 2, 3, \dots, n \quad (4-4)$$

其中， $Q$  为每个坐标轴曲线上信息熵的计算结果， $p_i$ 为该坐标各频率对应的幅值， $i$  为频率大小， $n=25$ 。

信息熵特征能够区分字形差别明显的字母，这些字母通常因为笔画种类和转折位置的不同，角速度存在差异。如图 4-6 所示，对于某一用户的大多字母样本集合{h,j,k,p,w,z}能通过特征 $f_{78}$ 区分。




图 4-6 信息熵特征 $f_{78}$ 区分字母集合{h,j,k,p,w,z}的效果展示。

(2) 陀螺仪相位特征：由于手腕与笔尖运动的特殊对应关系：手腕通过顺时针或逆时针转动控制笔尖运动。因此，陀螺仪角速度数据的相位特征更能直接反映字母笔画在连接、转折过程中的差异。例如，陀螺仪  $x$  和  $y$  坐标轴曲线通常保持相似的趋势，而  $z$  轴的曲线呈现相反的趋势，当陀螺仪数据在  $x$  和  $y$  轴上出现峰值，同时在  $z$  坐标轴曲线出现波谷时，用户很可能在纸面上完成了一组至上的笔画，手腕逆时针方向旋转。本文将总结陀螺仪三个坐标轴波峰和波谷之间的相位特征，并将其归纳为五类： $x$  轴曲线第一个波谷相关特征； $x$  轴曲线第一个波峰相关特征； $x$  轴曲线最后一个波峰相关特征； $x$  轴曲线最高波峰相关特征和最大最小值相关特征。由于绘图编排，本文将在图 4-7 中用 6 个示例图展示相位特征。最后，逐一分析特征在分类具备不同结构字母时候的效果。

在提取相位相关的特征之前，陀螺仪数据首先需要除以该样本所有序列中的绝对值最大值，将信号归一化到  $[-1, 1]$  区间，以消除写字力度的差异。

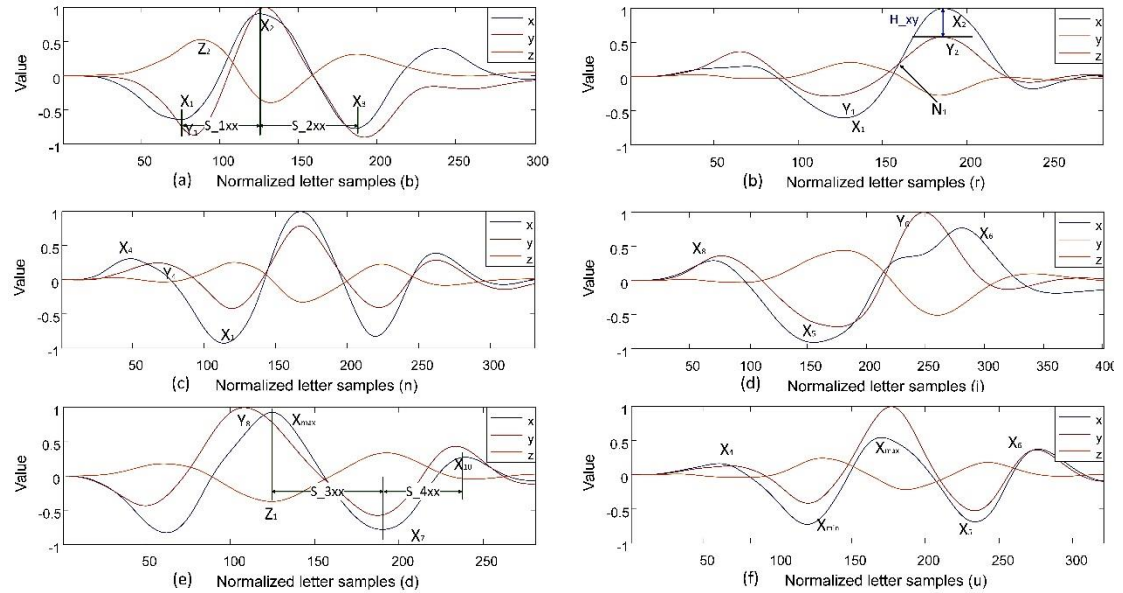


图 4-7 相位特征说明。(a)  $x$  轴第一个波谷相关特征，字母  $b$ ；(b)  $x$  轴第一个波谷相关特征，字母  $r$ ；(c)  $x$  轴第一个波峰相关特征，字母  $n$ ；(d)  $x$  轴最后一个波峰相关特征，字母  $i$ ；(e)  $x$  轴最高波峰相关特征，字母  $d$ ；(f) 最大最小值相关特征，字母  $u$ 。

**A.  $x$  轴曲线第一个波谷相关特征：**这一类特征是根据  $x$  轴曲线的前两个谷值计算而来的。根据图 4-7(a)，本文找到  $x$  曲线上的第一个数值低于  $-0.5$  的波谷，其位置标记为  $x_1$ ， $x_1$  的值作为特征  $f_{79}$ 。根据  $x_1$ ，本文定位与其最近的  $y$  轴的波谷  $y_1$  和  $z$  轴的波峰  $z_2$ 。本文将  $x_1$ ， $y_1$  和  $x_1$ ， $z_2$  的数值之差分别标记为  $f_{80}$  和  $f_{81}$ 。

$x$  轴曲线的第二个波谷标记为  $x_3$ 。本文将对  $x_1$  执行的运算运用到  $x_3$ ，获得特征  $f_{82}$ ， $f_{83}$  和  $f_{84}$ 。然后，本文选择  $x$  轴曲线在  $x_1$  和  $x_3$  之间的波峰  $x_2$ ，计算  $x_1$  和  $x_2$  数



值之差, 记为 $f_{85}$ 。如图 4-7(a)所示,  $s_{1xx}$ 和 $s_{2xx}$ 代表 $x_1$ 和 $x_2$ ,  $x_2$ 和 $x_3$ 之间的位置差异, 由 $s_{1xx} / s_{2xx}$ 计算得到特征 $f_{86}$ 。

因为图像空间的限制, 本文选择另一字母样本进一步解释第一类特征。在图 4-7(b)中, 本文标记 $y_1$ 之后的第一个波峰位置作为 $y_2$ ,  $H_{xy}$ 表示 $x_2$ 和 $y_2$ 之间数值之差。本文计算波谷 $y_1$ 和波峰 $y_2$ 的数值之差, 记为 $f_{87}$ 。特征 $f_{88}$ 由 $H_{xy} / f_{87}$ 获得,  $f_{89}$ 取值 0 或 1, 表示在 $y_1$ 和 $y_2$ 之间陀螺仪  $x$  与  $y$  轴曲线的交点 $N_1$ 是否存在。第一类特征可以帮助本文区分字母集合 $\{a, d, g, o, q, u, v, w, y\}$ 和 $\{b, h, k, m, n, r\}$ 。例如, 图 4-8 展示了分别在两组不同集合中的 4 个字母 $\{q, y\}$ 和 $\{b, h\}$ , 特征 $f_{82}$ 和 $f_{84}$ , 能够将来自同一集合中的字母划分为一类, 如图中  $q$  和  $y$ , 同时对于区分来自不同集合的字母效果较为明显。




图 4-8 陀螺仪  $x$  轴第一个波谷相关特征, 特征 $f_{82}$ 和 $f_{84}$ 对字母集合 $\{q, y\}$ 和 $\{b, h\}$ 分类效果。




图 4-9 陀螺仪  $x$  轴第一个波峰或波谷相关特征。特征 $f_{90}$ 和 $f_{92}$ 对字母集合 $\{n, r\}$ 和 $\{b, h\}$ 的分类情况。

**B.  $x$  轴曲线第一个波峰或波谷相关特征:** 这一类的特征是根据  $x$  和  $y$  轴曲线上的第一个峰值来计算的。在图 4-7(c)中, 本文找到  $x$  和  $y$  轴曲线上的第一个峰值, 分别用 $x_4$ 和 $y_4$ 来标记它们的位置。本文选择 $x_4$ 的数值作为特征 $f_{90}$ , 相应的计算 $x_4$ 和 $y_4$ ,  $x_4$ 和 $x_1$ 的数值之差, 分别记为 $f_{91}$ 和 $f_{92}$ 。若找到的  $x$  轴第一个极值为波谷, 则需要将数据求逆后按照上述方法计算特征。这些特征 $f_{90}$ ,  $f_{91}$ 和 $f_{92}$ 能够找到手写英文字母中起始笔画为上提的字母, 如 $\{i, j, m, n, p, r, u, v, w, x, y\}$ , 因此, 用于区分该集合字母和其他字母。例如, 图 4-9 展示了特征 $f_{90}$ 和 $f_{92}$ 对集合内 $\{n, r\}$ 和其他字母 $\{b, h\}$ 的分类情况, 区分效果明显。

**C.  $x$  轴曲线最后一个波峰相关特征:** 这一类的特征是根据  $x$  轴曲线上的最后一个峰值计算。本文找到  $x$  轴曲线上的最后一个大于 0.5 的波峰, 在图 4-7(d)中标记为 $x_6$ , 距离 $x_6$ 最近的  $y$  轴波峰位置标记为 $y_6$ ,  $x$  轴曲线上位于 $x_6$ 的前一个波峰和波谷分别标记为 $x_8$ 和 $x_5$ 。计算 $x_6$ 和 $y_6$ 两个峰值之间的差值, 记为特征 $f_{93}$ 。



计算 $x_6$ 和 $x_8$ 两个峰值之间的差值,记为特征 $f_{94}$ 。 $x_5$ 和 $x_6$ ,  $x_6$ 和 $y_6$ 之间的位置差异分别记为 $f_{95}$ 和 $f_{96}$ 。这些特征能够分离出由两笔组成的字母,包括{f, i, j, p, t, x}。图 4-10 展示了特征 $f_{93}$ 和 $f_{96}$ 对字母子集{f, t}和{e, l}的区分效果。




图 4-10 陀螺仪 x 轴最后一个波峰相关特征。 $f_{93}$ 和 $f_{96}$ 对字母子集{f, t}和{e, l}的分类情况。




图 4-11 陀螺仪 x 轴最高波峰相关特征。特征 $f_{100}$ 和 $f_{102}$ 对字母{a, b, c}的区分效果展示。

D. x 轴曲线最高波峰相关特征: 这里的特征类别是根据 x 轴曲线最高波峰计算它与后续峰值的关系。如图 4-7(e)所示,本文设置 x 轴曲线上最高波峰为 $x_{max}$ ,本文标记为 $y_8$ 和 $z_1$ 分别为 y 轴和 z 轴曲线上最靠近 $x_{max}$ 的波峰位置。计算 $x_{max}$ 和 $y_8$ ,  $x_{max}$ 和 $z_1$ 的数值之差,分别设定为 $f_{97}$ 和 $f_{98}$ 。x 轴曲线上紧随 $x_{max}$ 后的峰值位置标记为 $x_{10}$ ,该峰值记为 $f_{99}$ 。本文对 $x_{max}$ 的计算步骤应用到 $x_{10}$ ,并获得特征 $f_{100}$ 和 $f_{101}$ 。两波峰 $x_{max}$ 和 $x_{10}$ 之间的波谷位置表示为 $x_7$ ,而 $x_{max}$ 与 $x_7$ 之间的差值记为 $f_{102}$ 。 $s_{3xx}$ 和 $s_{4xx}$ 代表 $x_{max}$ 和 $x_7$ ,  $x_7$ 和 $x_{10}$ 之间的位置差异,由 $s_{3xx} / s_{4xx}$ 计算得到特征 $f_{103}$ 。将这类特征与第一类特征结合,本文可以定位每个字母笔画的主要发力位置,进而区分包含相似笔画的不同字母。图 4-11 展示了特征 $f_{100}$ 和 $f_{102}$ 对字母{a, b, c}的区分效果。

E. 最大最小值相关特征: 这里的特征类别是基于最大和最小相关特征来计算的。在图 4-7(e)中,本文获得三个轴曲线上的最大值和最小值,作为特征 $f_{104} - f_{109}$ 。然后,本文需确定每个最大值或最小值在对应坐标轴曲线上的编号。以 x 轴为例,如图 4-7(e)所示,本文根据上述方法标记所有波峰,波峰序列为{ $x_4, x_{max}, x_6$ },而波谷序列为{ $x_{min}, x_5$ }。本文选择 $x_{max}$ 和 $x_{min}$ 所在序号分别作为特征 $f_{110}$ 和 $f_{111}$ 。对于这里的例子:  $f_{110} = 2$ ,  $f_{111} = 1$ 。同理, y 和 z 轴上相应的最大值和最小值序号分别记作 $f_{112} - f_{115}$ 。这类特征可以帮本文确定手腕活动在不同方位上的重要转折点,对于区分书写时需要手腕运动方向频繁变化的字母效果较好。图 4-12 展示了特征 $f_{107}$ 对字母{a, d, q, r, y}的区分效果。




图 4-12 陀螺仪最大最小值相关特征。特征 $f_{107}$ 对字母{a, d, q, r, y}的区分效果展示。

(3) 加速度计频域特征：同陀螺仪特征 $\{f_1, f_2, \dots, f_{75}\}$ 的计算方式，本文选取 75 个加速度频域特征，分别为加速度计三轴曲线在 1Hz 到 25Hz 对应的幅值，用 $\{f_{116}, f_{117}, \dots, f_{190}\}$ 表示。这 75 个频率对应的幅值能够间接反映写字速度的周期变化，并随着字母结构差异，存在一定规律，由于需要多个特征共同作用两组字母实现分类，故不再一一展示。

表 4-1 总结了用于字母识别的所有时域和频域特征。

表 4-1：190 个用于字母分类的特征归纳

特征属性		特征序号
频率相关特征	陀螺仪频率幅值	$f_1 - f_{75}$
	加速度计频率幅值	$f_{116} - f_{190}$
	陀螺仪频率信息熵	$f_{76} - f_{78}$
相位相关特征	第一个波谷相关	$f_{79} - f_{89}$
	第一个波峰相关	$f_{90} - f_{92}$
	最后波峰相关	$f_{93} - f_{96}$
	最高峰相关	$f_{97} - f_{103}$
	最大最小值相关	$f_{104} - f_{115}$

#### 4.4.2 特征选择

随机森林中每个决策树内的节点都是关于某个特征的条件，根据条件不同，将数据集一分为二。随着决策树的增多，特征对数据集的分类越稳定。然而，冗余的特征必将带来繁琐的计算和耗时。本节将利用随机森林自身算法特点进行特征筛选，在不影响模型整体稳定性的前提下减少特征数量。

基于随机森林的特征筛选方法主要包括两种：平均不纯度减少和平均精度减少。然而，在使用平均不纯度减少方法时，当随机选择一个特征作为指示器（优秀特征）时，与其存在关联的其他特征的重要性会急剧下降。在理解数据时，无法解释优先选择的特征相比其他相关特征具有更大优势，因此本文并未使用。平均精确率减少方法直接衡量每个特征对模型精确度的影响程度，通过随机改变模型内特征顺序来达到衡量特征重要性的目的。

图 4-13 展示了利用平均精度减少算法，对五名志愿者每人各 50 组的手写英文字母数据进行分类的结果。对每名志愿者，提取 190 维的特征，按顺序依次加入训练模型，通过 5 折交叉验证获得每次加入一个特征后的字母分类准确率。可以看出，在加入第 80 个特征后，5 名志愿者的字母分类准确率不再有大幅度的提升，而从 120 个特征之后，第五名志愿者的字母分类准确率出现小幅度下降的趋势。这可能是因为加速度的频率特征受书写速度的影响较大，随着两次书写的时间间隔增长，书写速度会难以控制。另一方面，随机森林构建模型的方式决定了模型需要相当水平的特征数量来保持稳定，然而，FFT 是一项耗时和耗能的工作。为平衡模型鲁棒性和计算速度两项指标，本文只选取了与陀螺仪传感器相关的前 115 个特征组成最终字母分类特征集合，具体特征类型如表格 4-1 中的  $f_1 - f_{115}$  所示。




图 4-13 采用随机森林筛选特征。




图 4-14 HMM, SVM 和 Random Forest 分类器效果比较。

## 4.5 字母识别及评估

在本系统架构中，字母分类是单词分类的基础。为达到较为理想的单词分类准确率，本节将首先测试每位志愿者的手写字母分类准确率。

#### 4.5.1 实验设计

为验证不同分类器在本文数据结构中的效果，本文选择 HMM、SVM 和 Random Forest 进行比较。首先，分别从 A 组 5 名志愿者中选择 50 组字母训练样本，然后从中随机选择 40 组样本作为训练集，剩余 10 组样本作为测试集，分别用 HMM、SVM 和 Random Forest 分类器进行分类。通过对三种分类器分类准确率的比较，选择平均字母识别准确率最高，同时在不同志愿者数据集中均表现较好的分类器作为本文的分类器。

为评价特征选取的可靠性，观察特征是否在不同用户间均能保持较高的分类准确率；另外，是否存在容易混淆的字母。本文采用 A 组 5 名志愿者 6 天的所有字母训练数据进行实验，验证 115 个特征集合对于不同志愿者的字母样本分类情况。对于每名志愿者，文中选取其中 80% 的样本作为训练集，其余 20% 样本作为测试集，用分类器得到每个字母的分类结果。首先，通过不同志愿者的平均字母识别准确率评估特征集是否适用于不同类型数据。然后，通过累加所有志愿者的字母分类结果，得到有关 26 个字母分类的混淆矩阵，观察特征集合对不同字母的分类是否有效。

随着时间间隔、手写初始位置、写字速度等因素的变化，特征集是否依然能保持较高的分类准确率？本文设计实验，对特征集的鲁棒性进行评估。本文对 A 组每位志愿者不同天的字母分类准确率进行计算。以第一位志愿者为例，本文选取该志愿者第一天的 20 组字母手写数据作为训练集，依次测试其后每一天的 20 组数据，获得该志愿者每天的平均字母分类准确率。同样，对其他 4 名志愿者数据执行相同操作，最终得到每名志愿者首先字母分类准确率随时间的变化趋势。

为使用户达到更好的用户体验，本文需要评估合适的字母训练样本个数。首先，分别随机从 A 组每名志愿者中，各自随机选取 50 组手写字母数据，将一部分样本作为训练集，其余样本测试，计算字母分类准确率。然后，逐渐减少训练样本的个数，得到相应字母分类准确率。最后，统计 5 名志愿者的平均准确率，观察其变化趋势。

#### 4.5.1 实验评估

图 4-14 展示了不同分类器对于手写字母分类准确率的效果。图 4-14 可以观察到：Random Forest 在三种分类器中表现最好，对于不同志愿者的训练数据均能保持较高的准确率，这是因为在处理训练样本较少，而特征数较多的场景时，随机森林能够通过所有决策树共同分类，有效防止数据过拟合。




图 4-15 不同用户字母识别准确率。

图 4-15 展示 5 名志愿者单个字母的平均分类准确率,分别为 95.77%,87.55%,82.26%, 87.98%和 77.66%,这说明特征集合在不同用户的数据样本中均由较为理想的分类效果。同时,图 4-16 展示了 5 名志愿者手写字母平均分类准确率的混淆矩阵,大多数字母的分类结果理想,同时存在个别结构相似字母分类出现较多错误的情况。




图 4-16 共 5 名志愿者的手写字母平均分类准确率的混淆矩阵。

图 4-17 展示了 5 名志愿者字母分类准确率随时间变化的趋势:首先,所有志愿者的字母分类准确率都有不同程度地降低。其中,志愿者 1, 3 和 4 的字母分类准确率并没有发生较大幅度的下降,并且分别在第四天、第四天和第三天时有所上升;志愿者 2 和 5 的准确率在前四天下降明显,但是志愿者 2 的字母分类准确率在最后一天又回到较高水平。本文认为,字母分类准确率的变化可能取决于用户书写英文字母的熟练程度,因为本系统的字母识别依赖标准手写体的笔画,

这与个别用户以前的书写习惯有所不同，也就造成了某些志愿者的字母识别准确率处于较低的水平。当志愿者的书写逐渐规范后，字母识别的准确率便会保持在一定水平。




图 4-17 不同用户随天数变化下的字母分类




图 4-18 字母分类准确率随训练样本数量

准确率。

变化曲线。

最后，为验证训练样本个数对字母分类准确率的影响，确定最合适的训练集大小，本文通过逐步增加训练样本数量、观察字母分类准确率的方法进行验证。如图 4-18 所示，随着训练样本的增多，所有 5 名志愿者的字母分类准确率都有不同程度地上升，当训练样本达到 11 组时，其中四名志愿者的字母分类准确率基本趋于稳定，达到 80% 左右。由实验可知，当用户书写 10 组左右有效的手写字母数据后，便可实现系统的手写字母识别。

## 4.6 单词识别及评估

通常情况下，信息需要以单词为基本单位表达。在验证字母识别的有效性后，本文继续完成单词识别模块，并通过字典校验，修正拼写错误，提高单词识别准确率。

### 4.6.1 单词识别实验

经过 4.3 节的切割处理，每个单词均被切割成若干个字母。首先，参照 4.5 中的算法，用志愿者本人的字母分类模型，通过随机森林的方法预测单个手写字母；然后，将字母预测结果按照所在单词原位置排序，送入字典中。字典查找最可能单词，并返回预测结果。由于在单词切割模块已经对单词内部字母个数进行了修正，本文将单词内部的字母个数同样作为一项重要指标，在返回单词预测结果时，本文将所有具有正确字母个数的预测结果提前，作为该单词的预测结果。单词识别流程如图 4-19 所示。

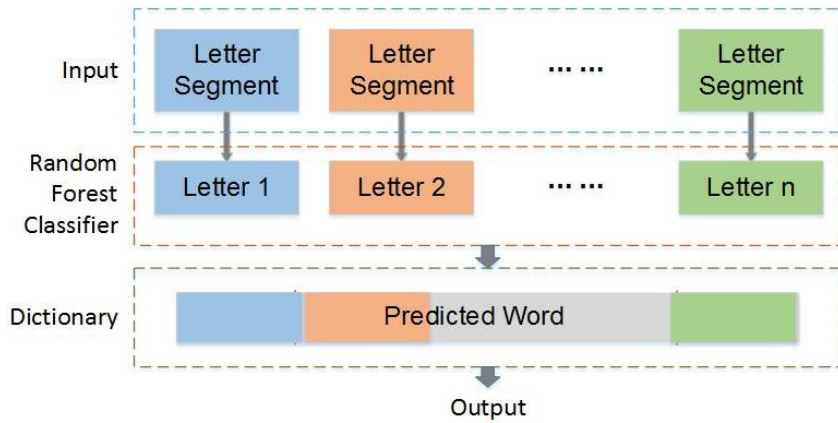


图 4-19 手写识别系统的单词识别流程图。

将单词切割后本文得到若干个字母段落，命名为“Letter Segment”。然后，通过随机森林分类后，获得对应的字母预测结果。将字母按顺序组合，送入字典中校正拼写，输出的单词便作为单词预测结果。

#### 4.6.2 单词识别系统评估

本文选取字典输出的第一个单词作为预测单词，并计算单词识别准确率。图 4-20 分别展示了 5 名志愿者书写的两篇文章（“老人与海”为“Paragraph 1”，“Writinghacker”为“Paragraph 2”）的平均单词识别准确率，从图中可以看出，两篇文章的平均单词识别准确率分别为 68.91%和 70.80%。其中，前四名志愿者两篇文章的平均单词识别准确率分别为 74.01%和 75.00%，而第五名志愿者的单词识别准确率明显低于平均值，分别为 48.51%和 54.00%，可能原因是该志愿者日




图 4-20 不同志愿者书写文章段落的单词识别准确率。

常较少写字，对手写行为生疏，其字母分类准确率随时间推移下降明显。

另外，图 4-20 显示，小说题材的手写段落单词识别平均准确率低于专业领域的手写段落约 2%，这可能是因为一些专业单词不易同其他单词混淆，字典校正

拼写的效果较好，而小说中涉及的多为简单的日常单词，存在较多相似拼写，在字典校正过程中易发生错误。

#### 4.7 本章小结

本章首先介绍了用户依赖的手写识别系统的逻辑架构；然后详细介绍每个模块原理方法和执行细节，包括：数据收集、数据预处理、数据切割、特征提取、字母识别和单词识别。通过手写识别系统和相对较少的手写字母训练数据，用户能够借助智能手表随时记录日常手写内容。实验得出，五名志愿者的平均字母识别准确率为 86.24%，平均单词识别准确率为 69.36%。



## 5 手写窃听系统

手写窃听系统是本文的另一项探索。相较手写识别系统，手写窃听系统是基于用户独立，也就是说：在预测受害者手写内容时，攻击者无法获取受害者手写字母样本作为训练模型。

本文将在本章验证特征集合在不同用户群体间的字母分类效果。首先，利用特征集合训练字母分类模型，使该模型能够根据他人的数据找到与字母字形结构相关的信息，然后将该模型应用到其他用户的数据中进行字母分类。同时，本文巧妙利用字典来纠正单词拼写，提高了单词识别的准确率。最后，根据单词识别的结果，本文得出基于智能手表惯性传感器的手写数据存在信息泄露的风险。

### 5.1 系统概述

本节将会对手写窃听系统的设计架构进行详细介绍，其框架和手写识别系统类似，包含：数据收集、数据预处理、数据切割、特征提取、字母识别和单词识别六大模块。其中，数据预处理模块和手写识别系统中的对应模块相同，其余五个模块因为场景不同，存在一定差异。各个模块构成和联系如图 5-1 所示。



图 5-1 手写监听系统结构示意图

(1) 数据收集模块：本次实验成员为 B 组未参加过手写识别实验的 5 名志愿者，本文称之为受害者（victim）。受害者在未被告知实验目的的前提下，各自在右手上（B 组参与实验的成员均使用右手写字），按照手写识别实验的方式佩戴安装有数据收集应用的智能手表。同时，每位受害者均按照手写识别实验中的要求，分别抄写两节段落各一次：《老人与海》第一段（Paragraph 1，101 字）和 WritingHacker<sup>[28]</sup>的 Conclusion 段落（Paragraph 2，100 字）。手表惯性传感器产生并记录相应的时间戳、加速度和陀螺仪数据，保存至手表内存空间。

(2) 数据预处理模块：与手写识别实验中的数据预处理模块相同。

(3) 数据切割模块：窃听系统的切割模块同文中 4.3.2 节的单词切割方法。首先确定每组手写内各个单词的具体边界，再逐一分离出单词内的所有字母。

(4) 特征提取模块：与手写识别实验中的特征提取模块相同，从切割获得的单个字母手写数据中提取特征，用于字母和单词预测。

(5) 字母识别模块：用攻击者收集的字母样本训练模型，攻击受害者样本数据。由于字母识别较低的准确率，本文选取最高概率的前 5 个字母作为候选结果。

(6) 单词识别模块：根据步骤(4)，组合出单词的所有可能排列，并借助字典筛选出最大概率单词，取概率最大的前五个单词作为单词预测候选结果。

## 5.2 字母识别及评估

### 5.2.1 字母识别实验设计

在获得受害者手写单词的字母切割结果后，本文需要借助除受害者以外的手写字母样本模型预测受害者的手写数据。因为惯性传感器记录的手腕运动轨迹并不能直接反应笔尖运动，即使在同一位置重复书写相同的单词，不同志愿者手腕运动轨迹也不相同，这使得许多反映用户书写习惯的特征不再适用于用户独立的场景，即该方法为用户依赖的。但是，不同字母间笔画的连接与转折是固定的且易于区分，如果所有用户遵守标准手写体格式书写单词，一些只与字母结构有关的特征便能在没有用户本人字母训练数据的情况下，识别出他人的手写数据。

为验证是否存在用户独立的手写窃听系统，本文首先进行了一组实验。对于A组成员的字母训练样本，本文随机选择一位志愿者的20组样本训练字母分类模型，攻击剩余4名志愿者的数据，用随机森林分类器获得其余志愿者字母识别的准确率。重新选择另一位志愿者的训练数据重复上述工作，直至遍历完所有志愿者的训练数据，计算A组成员在没有本人字母训练数据情景下的平均字母识别准确率。本文再次随机选择两名志愿者的字母训练数据做测试，攻击其余三名志愿者的数据，依此类推。最终，利用该组成员字母训练数据得到的26个小写英文字母的平均识别准确率。

### 5.2.2 字母识别系统评估

从图5-2中可以观测到：随着参与训练的志愿者人数增加，字母训练样本数量增加，攻击者对受害者的字母预测的平均准确率也逐渐上升。当选取4名志愿者的数据训练字母分类模型，攻击剩余一名志愿者的字母训练样本时，26个字母准确率的平均值和标准偏差分别是0.50和0.17。因此，若存在足够多的字母训练样本训练字母分类模型，攻击者将有可能在没有受害者字母训练样本的情况下，通过其他人的数据，预测受害者的写字内容。

由图5-2中数据得知，上述字母识别的结果不能直接应用到单词窃听中，因为识别出一个正确的，包含 $n$ 个字母的单词的概率只有 $(0.50)^n$ 。例如，本文只有3.1%的概率一次性预测正确一个包含 $n=5$ 的单词，这个结果强调了扩大候选字母个数和使用字典的必要性。因此，本文选取了随机森林中字母预测得票数最

高的前 5 个字母作为候选字母，本文将在下一节详细介绍如何利用字母分类结果进行单词识别。




图 5-2 用随机森林获得用户独立情景下的字母识别平均准确率。

### 5.3 单词识别及评估

与手写识别系统不同的是，手写窃听系统的字母分类准确率低，用字典校正拼写后，还原正确单词的概率也不够高。因此，本文通过给出更多的单词预测结果的方法，筛选得到正确的单词。

#### 5.3.1 单词识别

为尽可能提高正确单词出现的几率，本文选择了概率最大的前 5 个字母，并依照字母位置组合出所有可能单词。例如：对于一个长度为 2 的单词，第一个字母标记为  $letters_1$ ，其前五个的预测结果为  $\{letters_{11}, letters_{12}, letters_{13}, letters_{14}, letters_{15}\}$ ，第二个字母的预测结果标记为  $\{letters_{21}, letters_{22}, letters_{23}, letters_{24}, letters_{25}\}$ ，则该单词可能的排列方式有  $\{letters_{11}, letters_{21}\}, \{letters_{11}, letters_{22}\}, \{letters_{11}, letters_{23}\}, \dots, \{letters_{15}, letters_{25}\}$ ，共  $5^2=25$  种。然后，本文将所有的单词组合输入字典，通过字典返回单词纠正拼写后的结果。因为，只要输入的字母组合包含正确字母，字典便有可能输出正确单词。所以，本文统计了通过字典校验后的所有单词的出现频率，并将出现频率最高的单词作为预测结果。算法 1 展示了从组合单词到单词预测的全过程，‘letters’为单词‘word’内所有字母的集合，N 为单词长度，u 为候选字母个数。首先，建立有向图 G，连接前一个字母到下一个字母的所有

可能排序。然后，通过深度遍历算法输出所有单词，放入数组‘Predict’中。最后，统计单词出现频率，得到单词预测结果。

**Algorithm 1** Word Prediction

---

```

1: Input: letters[N]  $\in$  word, u, G, static TempWord;
2: Initialize: number of letters N,  $u = 5$ , G = NULL, TempWord = NULL;
3: %Build signed directed graph.
4: for i = 1 to N-1 do
5:   for j = 1 to u do
6:     for k = 1 to u do
7:       letters[i][j].adjacent = letters[i+1][k];
8:       letters[i][j].visited = 0;
9:     end for
10:   end for
11: end for
12: G.adjacent = letters[1];
13: G.visited = 0;
14: % Group word by depth-first search.
15: Predict = DFS(G);
16: Output Highest frequency word in Predict;
17:
18: void DFS(w){
19:   w.visited = 1;
20:   for each w.adjacent do
21:     if w.visited == 0 then
22:       TempWord = [TempWord,w]; %append w to TempWord
23:       DFS(w.adjacent)
24:     end if
25:   end for
26: %Correct word by dictionary.
27: for each TempWord do
28:   % Record top 5 words from dictionary.
29:   Predict = [Predict, Dictionary(TempWord)]; %append Dictionary results to Predict
30: end for
31: return Predict;
32: }
```

---

### 5.3.2 单词识别系统评估

图 5-3 给出了受害者抄写的两篇段落的单词识别平均准确率，本文分别在第一个预测结果和前 5 个预测结果中寻找正确单词：当直接选择单词的第一个预测结果时，攻击者能够分别识别 5 名受害者两篇手写段落平均 31.9%和 33.6%的内容；当选择前 5 个单词预测结果时，包含正确单词的平均概率能够达到 48.8%。由此可见，在没有受害者任何数据的前提下，攻击者可以通过受害者佩戴的智能手表，从惯性传感器数据中还原大约 1/3 的内容。然而，多数人在书写大段文字时都是包含上下文的。通过上下文分析工具，攻击者能从前 5 个备选单词中删除大量无意义的单词，得到大约 1/2 的手写内容。因此，该实验证实了智能手表上的惯性传感器存在泄露用户手写内容的风险。




图 5-3 五名受害者两篇文章的单词识别准确率。

## 5.4 本章小结

本章首先介绍了用户独立的手写窃听系统的逻辑架构；然后详细介绍每个模块原理方法和执行细节，包括：数据收集、数据预处理、单词切割、字母识别和单词识别。攻击者在没有受害者手写字母样本数据的情况下，通过其他人的手写字母样本预测受害者手写数据。从结果中可以看出：攻击者在获取受害者智能手表运动数据后，能直接获取受害者大约 1/3 的手写内容，经过上下文分析后，更有可能获得受害者 50% 的手写内容。因此，本实验证明了智能手表具有泄露手写信息内容的风险。

## 6 总结与展望

本章总结了全文的研究内容,并对基于智能手表惯性传感器的手写识别和窃听技术今后的研究方向进行了展望。

### 6.1 总结

可穿戴设备的发展与普及让计算机更多的了解用户,同时,也为攻击者提供更多的渠道窥探用户隐私。本文首先讨论了手写识别系统的应用场景和模块组成,并对该系统的单词识别准确率进行评估。然后利用字母结构的特性,提出了基于用户独立的手写窃听系统,从实验上论证了智能手表惯性传感器数据能够泄露用户书写内容的风险。

本文的主要工作总结如下:

(1) 深入详细地分析了目前有关基于可穿戴设备惯性传感器的手写识别研究和手写信息窃取的各类途径,通过相关工作阐明了本文研究的理论基础,同时,说明本文的研究内容和研究意义。

(2) 设计实验数据的收集流程,完成数据收集系统在 Android Wear 平台的开发。分析数据,指出原始惯性传感器数据的四大特点,为后续分类研究提供方案。

(3) 解决小幅度动作切割问题。通过观察传感器各坐标轴在静止与运动时段数据,总结两者间差别,并通过加速度计和陀螺仪数据特征对单词和字母进行切割。

(4) 提取并筛选出 115 个频率与相位特征用于字母和单词分类。随机森林能在较少训练样本的情况下减少过拟合,以达到较高的字母识别准确率。实验评估手写英文单词的识别准确率。

(5) 评估手腕运动是否泄漏手写信息。设计实验观察惯性传感器记录的手腕写字运动是否能造成信息泄露,最终验证本猜想,并获得信息在不同条件下的泄露比例。

### 6.2 展望

可穿戴设备的普及不仅给科研工作带来机遇,使手写识别能够在只借助内置惯性传感器的智能手表上完成,同时也是一项挑战,更多的渠道能够被他人用来获取用户隐私。本文针对 Android Wear 平台下的智能手表提出了两个系统:手写识别系统和手写窃听系统,前者需要用户本人的训练数据而后者是通过他人的数据识别受害人手写信息,是用户独立的。但是目前,手写识别系统仍然不能

---

实现实时的手写单词识别,因为单词的切割和识别效率依然无法与书写速度同步,同时,用户必须遵循标准英文小写体来书写。为达到更加自然的人机交互效果,本文今后需要继续从三方面入手:

(1) 改善字母和单词切割方法,研究实时确定单词边界,并分离单个字母的有效方案,提高字母和单词切割的速度和准确率。

(2) 提高字母分类的准确率,继续寻找能够反映字母笔画和结构的特征,消除因为初始位置、握笔方式、写字速度、力度等因素引起的分类准确率降低。相信随着技术的进步,手写识别研究一定会给人们生活带来巨大的便利,而手写动作窃听的行为将被有效避免。

(3) 发展基于手写识别的信息输入方式,帮助用户在小屏幕设备上完成更为友好的人机交互。

### 参考文献

- [1] Martin Bauer, Lamine Jendoubi, and Oliver Siemoneit. 2004. Smart Factory–Mobile Computing in Production Environments. In the MobiSys 2004 Workshop on Applications of Mobile Embedded Systems (WAMES 2004).
- [2] Wang X, Tarró P, Metola E, et al. Gesture recognition using mobile phone's inertial sensors[M]. Distributed Computing and Artificial Intelligence. Springer Berlin Heidelberg, 2012: 173-184.
- [3] Scottmackenzie I, Zhang S, Williamsoukoreff R. Text entry using soft keyboards[J]. Behaviour & Information Technology, 1999, 18(4):235-244.
- [4] Leiva L A, Sahami A, Catala A, et al. Text Entry on Tiny QWERTY Soft Keyboards[J]. 2015:669-678.
- [5] Константин Николаевич Касьян. Development of modified method for text recognition in standardized picture[J]. 2015, 3(2(75)):11.
- [6] Tappert C C, Suen C Y, Wakahara T. State of the art in on-line handwriting recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1990, 12(8):787-808.
- [7] Breuel T M. Handwriting Recognition[C]// Invited Session Papers from the Second Asian Conference on Computer Vision: Recent Developments in Computer Vision. Springer-Verlag, 1995:447-456.
- [8] Liu C L, Nakashima K, Sako H, et al. Handwritten digit recognition using state-of-the-art techniques[C]// Frontiers in Handwriting Recognition, 2002. Proceedings. Eighth International Workshop on. IEEE, 2002:320-325.
- [9] Smoker T J, Murphy C E, Rockwell A K. Comparing Memory for Handwriting versus Typing[J]. Human Factors & Ergonomics Society Annual Meeting Proceedings, 2009, 53(22):1744-1747.
- [10] Longcamp M, Boucard C, Gilhodes J C, et al. Remembering the orientation of newly learned characters depends on the associated writing knowledge: a comparison between handwriting and typing.[J]. Human Movement Science, 2006, 25(4-5):646.
- [11] Pylvänäinen T. Accelerometer based gesture recognition using continuous HMMs[M]. Pattern Recognition and Image Analysis. Springer Berlin Heidelberg, 2005: 639-646.
- [12] Niezen G, Hancke G P. Gesture recognition as ubiquitous input for mobile phones[C]. International Workshop on Devices that Alter Perception (DAP 2008), in conjunction with Ubicomp. 2008: 17-21.
- [13] [https://en.wikipedia.org/wiki/Fat-finger\\_error](https://en.wikipedia.org/wiki/Fat-finger_error)
- [14] Balzarotti D, Cova M, Vigna G. ClearShot: Eavesdropping on Keyboard Input from Video[C]// IEEE Symposium on Security and Privacy. IEEE Computer Society, 2008:170-183.



- 
- [15] Asonov D, Agrawal R. Keyboard acoustic emanations[C]// Security and Privacy, 2004. Proceedings. 2004 IEEE Symposium on. IEEE, 2004:3-11.
- [16] Amma C, Georgi M, Schultz T. Airwriting: Hands-Free Mobile Text Input by Spotting and Continuous Recognition of 3d-Space Handwriting with Inertial Sensors[C]// International Symposium on Wearable Computers. IEEE, 2012:52-59.
- [17] Chao Xu , Parth H. Pathak , Prasant Mohapatra, Finger-writing with Smartwatch: A Case for Finger and Hand Gesture Recognition using Smartwatch, Proceedings of the 16th International Workshop on Mobile Computing Systems and Applications, February 12-13, 2015, Santa Fe, New Mexico, USA [doi>10.1145/2699343.2699350]
- [18] Thomas Plätz , Gernot A. Fink, Markov models for offline handwriting recognition: a survey, International Journal on Document Analysis and Recognition, v.12 n.4, p.269-298, November 2009 [doi>10.1007/s10032-009-0098-4]
- [19] Ardüser L, Bissig P, Brandes P, et al. Recognizing text using motion data from a smartwatch[C]// IEEE International Conference on Pervasive Computing and Communication Workshops. IEEE, 2016:1-6.
- [20] Deselaers T, Keysers D, Hosang J, et al. GyroPen: Gyroscopes for Pen-Input With Mobile Phones[J]. IEEE Transactions on Human-Machine Systems, 2015, 45(2):263-271.
- [21] Li Y, Yao K, Zweig G. Feedback-based handwriting recognition from inertial sensor data for wearable devices[C]// IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2015:2269-2273.
- [22] He Wang , Ted Tsung-Te Lai , Romit Roy Choudhury, MoLe: Motion Leaks through Smartwatch Sensors, Proceedings of the 21st Annual International Conference on Mobile Computing and Networking, September 07-11, 2015, Paris, zFrance [doi>10.1145/2789168.2790121]
- [23] J. S. Wang, Y. L. Hsu and C. L. Chu, "Online handwriting recognition using an accelerometer-based pen device," 2nd International Conference on Advances in Computer Science and Engineering, pp. 229--232, 2013.
- [24] Emmanuel Owusu, Jun Han, Sauvik Das, Adrian Perrig, and Joy Zhang, "Accessory: Password inference using accelerometers on smartphones," in Proceedings of the Twelfth Workshop on Mobile Computing Systems and Applications. 2012, HotMobile '12, pp. 9:1–9:6, ACM.
- [25] Liang Cai and Hao Chen, "TouchLogger: Inferring keystrokes on touch screen from smartphone motion," in Proceedings of the 6th USENIX Conference on Hot Topics in Security. 2011, HotSec'11, pp. 9–9, USENIX Association.
- [26] Liu X, Zhou Z, Li Z, et al. When Good Becomes Evil: Keystroke Inference with Smartwatch[C]// ACM Sigsac Conference on Computer and Communications Security. ACM, 2015:1273-1285.

- 
- [27] A. Maiti, M. Jadliwala, I. Bilogrevic, and I. Bilogrevic, “(smart)watch your taps: side-channel keystroke inference attacks using smartwatches,” in ACM International Symposium on Wearable Computers, pp. 27–30, 2015.
- [28] Yu T, Jin H, Nahrstedt K. WritingHacker: audio based eavesdropping of handwriting via mobile devices[C]// ACM International Joint Conference on Pervasive and Ubiquitous Computing. ACM, 2016:463-473.
- [29] Goldberg D, Richardson C. Touch-typing with a stylus[C]// INTERACT '93 and CHI '93 Conference on Human Factors in Computing Systems. ACM, 1993:80-87.
- [30] Amma C, Georgi M, Schultz T. Airwriting: Hands-Free Mobile Text Input by Spotting and Continuous Recognition of 3d-Space Handwriting with Inertial Sensors[C]// International Symposium on Wearable Computers. IEEE, 2012:52-59.
- [31] Ardüser L, Bissig P, Brandes P, et al. Recognizing text using motion data from a smartwatch[C]// IEEE International Conference on Pervasive Computing and Communication Workshops. IEEE, 2016:1-6.
- [32] Dynamic Time Warping[M]// Information Retrieval for Music and Motion. Springer Berlin Heidelberg, 2007:69-84.
- [33] Li Y, Yao K, Zweig G. Feedback-based handwriting recognition from inertial sensor data for wearable devices[C]// IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2015:2269-2273.
- [34] Carpenter G A. Neural network models for pattern recognition and associative memory[M]. Elsevier Science Ltd. 1989.
- [35] [https://en.wikipedia.org/wiki/Android\\_Wear](https://en.wikipedia.org/wiki/Android_Wear).
- [36] [https://en.wikipedia.org/wiki/Hidden\\_Markov\\_model](https://en.wikipedia.org/wiki/Hidden_Markov_model).
- [37] Thad Starner, Alex Pentland. Real-Time American Sign Language Visual Recognition From Video Using Hidden Markov Models. Master's Thesis, MIT, Feb 1995, Program in Media Arts.
- [38] Satish L, Gururaj BI (April 2003). "Use of hidden Markov models for partial discharge pattern classification". IEEE Transactions on Dielectrics and Electrical Insulation.
- [39] 高翔, 任国春, 陈瑾, 等. 认知无线电中频谱预测技术的研究与分析[J]. 军事通信技术, 2013, 3: 006.
- [40] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.
- [42] Breiman L. Random Forest[J]. Machine Learning, 2001, 45:5-32.
- [42] Goldberg D, Richardson C. Touch-typing with a stylus[C]// INTERACT '93 and CHI '93 Conference on Human Factors in Computing Systems. ACM, 1993:80-87.
- [43] <https://baike.baidu.com/item/%E6%8B%89%E4%BE%9D%E8%BE%BE%E5%87%86%E5%88%99/5678473?fr=aladdin>

- 
- [44]<http://www.baike.com/wiki/%E5%B7%B4%E7%89%B9%E6%B2%83%E6%96%AF%E6%BB%A4%E6%3%A2%E5%99%A8>
- [45]<http://www.baike.com/wiki/%E5%88%87%E6%AF%94%E9%9B%AA%E5%A4%AB%E6%BB%A4%E6%B3%A2%E5%99%A8>
- [46][http://www.baike.com/wiki/%E8%B4%9D%E5%A1%9E%E5%B0%94%E6%BB%A4%E6%B3%A2%E5%99%A8&prd=button\\_doc\\_entry](http://www.baike.com/wiki/%E8%B4%9D%E5%A1%9E%E5%B0%94%E6%BB%A4%E6%B3%A2%E5%99%A8&prd=button_doc_entry)
- [47] Ardüser L, Bissig P, Brandes P, et al. Recognizing text using motion data from a smartwatch[C]// IEEE International Conference on Pervasive Computing and Communication Workshops. IEEE, 2016:1-6.
- [48] Li Y, Yao K, Zweig G. Feedback-based handwriting recognition from inertial sensor data for wearable devices[C]// IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2015:2269-2273.
- [49] Hong F, You S, Wei M, et al. MGRA: Motion Gesture Recognition via Accelerometer[J]. Sensors, 2016, 16(4):530:1-25.
- [50]<https://baike.baidu.com/item/%E4%BF%A1%E6%81%AF%E7%86%B5/7302318?fr=aladdin>

## 致谢

时光如梭，我的研究生生活就要结束了，在本论文即将完成之际我向我的母校，以及所有直接或间接给予我帮助的老师、同学表示衷心的感谢。

首先，感谢我的母校——XXXX 大学。时间飞逝，我已经在 X 大走过了 7 个年头。X 大是我梦想起航的地方，它带给了我很多美好的回忆。在 X 大，我不仅实现了自己的梦想，也收获了师生情，友情……，在这即将离开的日子里，我越发不舍，想念海大恢弘的图书馆，想念海大落英缤纷的樱花大道，想念图书馆旁的满湖的荷花，想念和同学分一起学习奋斗过的教室……，这些地方都留下了我美好的回忆。

感谢我的导师 XX 教授，在生活中，我的导师亦师亦友，对学生百般关心照顾。在治学态度上，他那严谨的治学精神，精益求精的工作作风，也深深地感染了我，使我受益良多。还要感谢导师在本文研究过程中给予的悉心指导和帮助。本文从选题到构思，再到实验，以及最后的撰写和修订的整个过程中，都是在我的导师 XX 教授的细心指导下和帮助下完成的。在这里我由衷的对我导师说声谢谢。

还要感谢实验室的师兄师姐师弟师妹们，和他们并肩工作学习的日子是我人生中美好的回忆，他们的陪伴，给我的学习，生活以及科研带来了许多欢乐和帮助。跟他们一起学习生活日子是我人生珍贵的记忆。

感谢我的家人，感谢他们伟大的爱和无私的奉献，他们是我坚强的后盾。谢谢他们为我付出的一切，他们的支持永远都是我不断前进的力量源泉。

今天我所取得的成绩，与父母老师对我的教育，与同学和朋友对我的帮助和鼓励密不可分。最后，感谢所有关心和支持我的人，他们是我人生极为宝贵的财富。

## 个人简历、攻读硕士学位期间发表的学术论文

### 个人简历

1993 年 4 月 21 日出生于湖南省邵阳市。

2011 年考入 XXXX 大学信息科学与工程学院计算机科学与技术专业，2015 年 6 月本科毕业并获得工学学士学位。

2015 年 9 月考入 XXXX 大学信息科学与工程学院计算机系计算机技术专业，攻读硕士学位至今。

### 发表的学术论文和研究成果

[1] MotionHacker: Motion Sensor based Eavesdropping on Handwriting via Smartwatch. Infocom Workshops, Mobisec security privacy and digital forensics mobile systems and networks, 2018.



中国海洋大学  
OCEAN UNIVERSITY OF CHINA

# 硕士学位论文

